

1 なぜ Pearl 流が必要か

1.1 因果とは何か

「相関は因果を意味しない」これは多くの統計学の教科書に書かれている初等的な注意である。しかし、実際に単なる相関と因果の違いを説明するのは困難である。これに対して、Rubin は次の平均処置効果 (Average Treatment Effect: ATE) を因果効果として定義した。

$$ATE = E[Y^{(1)} - Y^{(0)}].$$

ここで、 $Y^{(1)}, Y^{(0)}$ はポテンシャルアウトカムと呼ばれる変数である。よく知られているように、Rubin の因果推論では、ポテンシャルアウトカムは同時に観測されず片方は必ず欠測するという欠測問題として因果推論の問題をとらえる。この定義は式で書くと非常に明快であるが、因果と相関の違いは何かという根本的な問いに答えられていないようにも感じる。

1.2 回帰係数は因果を意味するか

我々が統計学や因果推論に期待することの一つは意思決定への寄与である。つまり、原因となる変数が 1 単位変われば結果はいくら変わるのかという点である。これは、直感的に単なる相関ではなく因果関係を要求することは想像に難くない。

何千回と擦られた例であるが、アイスクリームの消費量と溺死者数は因果関係でなく相関関係である。つまり、行政の介入によりアイスクリームの流通を規制したとしても溺死者数を下げる結果には至らない。




図1 アイスクリームの消費量と月別の溺死者数

ところで、「原因となる変数が 1 変われば結果がいかに変わるのか」という文言は目的変数を説明変数で回帰したときの回帰係数の解釈として根付いている。図 1 を見れば、回帰係数は 0.04 であるから「アイスクリームの消費量を 100 円減らせば溺死者数が 4 人減る」という解釈ができる。

これは相関の意味では正しいといえるが、因果の意味では正しいとは言えない。換言すれば、観察の結果としての予測としては正しいが、原因に対する介入によって得られる結果の予測ではない。

線形回帰モデルの回帰係数に期待することが因果関係である場合、観察から得られた説明変数を全投入あるいは AIC や BIC によって変数選択することは得策とは言えない。

次のようなデータ生成を考えよう.

$$\begin{aligned}\varepsilon_X, \varepsilon_Y, \varepsilon_1, \dots, \varepsilon_6 &\stackrel{\text{i.i.d.}}{\sim} N(0, 1) \\ X &= 0.6Z_1 + 0.6Z_5 + \varepsilon_X \\ Y &= X + 0.6Z_2 + 0.6Z_3 + 0.6Z_6 + \varepsilon_Y \\ Z_1 &= 0.6Z_2 + \varepsilon_1 \\ Z_2 &= \varepsilon_2 \\ Z_3 &= 0.5X + \varepsilon_3 \\ Z_4 &= 0.7X + 0.7Y + \varepsilon_4 \\ Z_5 &= \varepsilon_5 \\ Z_6 &= \varepsilon_6\end{aligned}$$

ここで, 変数そのものが ε として与えられた変数を**外生変数**という. 式では見にくいので, 左辺を結果, 右辺を原因として原因から結果へ矢線を引いて変数の関係を視覚的に表したグラフが G(図 2) である.




図 2 データの生成過程

図 2 を見れば, どの矢線に沿って移動したとしても一周していないことが分かる. これは, 因果関係には原因と結果があり, 一方向にしか進まないというある種哲学的な要請である. このように頂点間の関係に向きがあり, どの矢線に沿って移動しても一周しないグラフを**非巡回有向グラフ** (Directed Acyclic Graph: DAG) といい, 詳しい定義は 3 章で扱う.

Y と他の変数の関係は線形であるため, Y を説明変数とし, X と他の変数を説明変数とした重回帰分析を行えば Y と X の関係を捉えられるかもしれない. 今回はモデルの当てはまりの問題を考え, BIC による変数選択を行った. 選ばれた変数とその偏回帰係数を表 1 に示す.

表 1 BIC 最善モデルによるシミュレーション結果 (n=10000)

項目	X	Z_2	Z_3	Z_4	Z_6
偏回帰係数	0.3577	0.4029	0.3969	0.4619	0.4116

この偏回帰係数は因果的な関係— X を 1 単位増加させれば Y は約 0.358 増加する—を表しているだろうか. これを確かめるために, シミュレーションにより因果効果を導出してみよう.

次のようなデータの生成と対応する DAG $G_{\bar{X}}$ を考える.

$$\begin{aligned}\varepsilon_Y, \varepsilon_1, \dots, \varepsilon_6 &\stackrel{\text{i.i.d.}}{\sim} N(0, 1) \\ X &= x \\ Y &= X + 0.6Z_2 + 0.6Z_3 + 0.6Z_6 + \varepsilon_Y \\ Z_1 &= 0.6Z_2 + \varepsilon_1 \\ Z_2 &= \varepsilon_2 \\ Z_3 &= 0.5X + \varepsilon_3 \\ Z_4 &= 0.7X + 0.7Y + \varepsilon_4 \\ Z_5 &= \varepsilon_5 \\ Z_6 &= \varepsilon_6\end{aligned}$$




図3 介入後のデータの生成過程

これは, X の値を強制的に x とした場合のデータの生成であり, 構造方程式としては X のデータの生成過程を破棄して, x という値に固定したといえる. このグラフ $G_{\bar{X}}$ のデータの生成において, $x = 1$ のときの Y の平均値と $x = 0$ の場合の Y の平均値の差が実際の因果効果といえる. 精密な定義は第5章で与えられる.

実際に 10000 回のシミュレーションによって計算した結果は以下のとおりである.




図4 ATE の計算結果

図3の計算結果により，真の因果効果— X が1単位変化したときの Y の変化量—は約1.3であることが分かる．この値は先の BIC による変数選択によって得られた偏回帰係数 0.358 とは乖離しており，この偏回帰係数は因果的な解釈性を持たないことが分かる．

では，回帰係数に因果的な解釈ができる変数の組み合わせは存在するのであろうか．

1.3 強く無視できる割り当て条件の謎

次の強く無視できる割り当て条件は Rubin の因果推論の中心的な仮定である．

$$(Y^{(1)}, Y^{(0)}) \perp X \mid Z.$$

ただし， X は処置変数， Z は共変量である．この場合 Z として選択してもよい変数はどんな変数であろうか．図5,6のデータ生成の場合でそれぞれ考えよう．




図5 交絡因子の構造




図6 合流点の構造

図5の場合は

$$\begin{aligned} \varepsilon_X, \varepsilon_{Y_1}, \varepsilon_Z &\stackrel{\text{i.i.d.}}{\sim} N(0, 1) \\ Z &= \varepsilon_Z \\ X &= \alpha_{XZ}Z + \varepsilon_X \\ Y^{(1)} &= \alpha_{Y_1Z}Z + \varepsilon_{Y_1} \end{aligned}$$

というデータの生成を考えれば，簡単な計算により条件付き独立性 $Y^{(1)} \perp X \mid Z$ が満たされていることが分かる．ちなみに，第4,5章にて外生変数の正規性や構造方程式の線形性にとらわれずにより一般的な仮定の下で条件付き独立性が導かれる．

一方で，図6の場合を考えみよう．次のデータの生成を考える．

$$\begin{aligned} \varepsilon_X, \varepsilon_{Y_1}, \varepsilon_Z &\stackrel{\text{i.i.d.}}{\sim} N(0, 1) \\ X &= \varepsilon_X \\ Y^{(1)} &= \varepsilon_{Y_1} \\ Z &= \alpha_{ZX}X + \alpha_{ZY_1}Y^{(1)} + \varepsilon_Z \end{aligned}$$

この場合は， $Y^{(1)} \perp X$ が成り立っており，簡単な計算により条件付き独立性 $Y^{(1)} \perp X \mid Z$ が成り立たず，むしろ条件を付けることで独立性が崩れていることが分かる．

このように条件付き独立性はデータの生成過程と密接に関係していることが分かる．では，DAG が与えられたときに条件付き独立性を保証するために必要な変数の集合はどんな集合であろうか．

1.4 Pearl 流が解決するもの

第 1 章を通して次のような疑問が浮かんでくる。

- 因果効果とは何か？
- 回帰係数に因果的な解釈は求められるか？
- 強く無視できる割り当て条件を満足する変数の集合はどんな集合か？

Pearl 流はこれらすべての疑問に (適切な仮定の下で) 答えてくれる理論である。本ゼミでは 2 章以降で以下の流れで章立てして進める (ことを目標にする)。

第 2 章では、古典的な構造方程式モデリングを扱う。第 1 章で見たように DAG に基づいて、外生変数に正規分布を、変数間に線形性を仮定して解析を進める枠組みである。構造方程式モデリングは、Pearl 流因果推論における特殊な場合を扱っているに過ぎない。しかし、グラフ構造と因果効果が綺麗に一対一対応する点、後の理論の基礎になっている点、歴史的経緯や第 6 章で扱う LiNGAM の理論において不可欠である点を鑑み取り上げることにした。また、この章では第 3 章以降のグラフ理論の用語や定理が時々顔を覗かせるになるが、その点をご容赦願いたい。

第 3 章では、本ゼミで取り扱う範囲のグラフ理論の基礎を取り上げる。この章によって DAG の定義や性質が与えられる。

第 4 章では、ベイジアンネットワークを取り扱う。この理論の提唱者は Judea Pearl 先生であり、グラフ構造に確率分布を対応させた理論である。本章によって条件付き独立性とグラフ構造が対応することが分かる。

第 5 章では介入を取り扱う。この章で与えられる介入及び因果効果の定義こそ「因果効果とはなにか？」という問いに対する Pearl 流における数学的な答えである。また、この章で示されるバックドア基準によって選択される変数集合こそがその他の疑問に対する現代的な答えである。

第 6 章では因果探索について取り扱う。ここまでの議論は DAG が既知のものであるとしてきたが、因果探索は手元のデータから DAG の復元を試みる分野である。

2 構造方程式モデリング

定義 2.1：構造方程式

確率変数 $X_1, \dots, X_n$ と誤差項 $\varepsilon_1, \dots, \varepsilon_n$ について、次の関係が成り立つとする。

$$\varepsilon_1, \dots, \varepsilon_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$$

$$X_i = \sum_{j < i} \beta_{ij} X_j + \varepsilon_i$$

この方程式を**構造方程式**という。また、係数 β_{ij} をパス係数という。

また、 $X = (X_1, \dots, X_n)^T$, $e = (\varepsilon_1, \dots, \varepsilon_n)^T$, $B = (b_{ij})_{i,j=1}^n$ を

$$b_{ij} = \begin{cases} \beta_{ij} & (j < i) \\ 0 & (\text{otherwise}) \end{cases}$$

とおいたときに、

$$X = BX + e$$

と書ける。 B は**狭義下三角行列**である。

$X_1, \dots, X_n$ について、構造方程式の右辺の変数から左辺の変数へ矢線を引きグラフを作ると、そのグラフは非巡回になる。なぜなら、 X_i から X_j への矢線が存在する場合 $i < j$ であるため、矢線に沿って移動したとき、添字は単調増加する。故に、巡回は発生しない。

逆に、DAG が与えられた場合でも、命題 3.10 に述べるトポロジカルソートを施すことにより、構造方程式の形で記述できる。つまり、構造方程式においては、添字の大小は本質的ではなく、DAG としての構造こそが本質的である。また、下三角行列 B は重み付き隣接行列に対応する。

例 2.2：擬似相関

構造方程式が次のように定義されているとする：

$$\varepsilon_1, \varepsilon_2, \varepsilon_3 \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$$


$$\begin{cases} X_1 = \varepsilon_1 \\ X_2 = \beta_{21}X_1 + \varepsilon_2 \\ X_3 = \beta_{31}X_1 + \varepsilon_3 \end{cases}$$

このとき、

$$E[X_2 X_3] = \beta_{21} \beta_{31}$$

を X_2, X_3 の**擬似相関**という。

この構造方程式に対応する DAG は以下の通りである。



この擬似相関は因果関係を意味しない。この相関は、 X_2 と X_3 に共通の原因 X_1 が存在するために引き起こされる。

例 2.3：直接効果・間接効果・総合効果

構造方程式が次のように定義されているとする：

$$\varepsilon_1, \varepsilon_2, \varepsilon_3 \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$$


$$\begin{cases} X_1 = \varepsilon_1 \\ X_2 = \beta_{21}X_1 + \varepsilon_2 \\ X_3 = \beta_{31}X_1 + \beta_{32}X_2 + \varepsilon_3 \end{cases}$$

このとき、

$$\begin{aligned} E[X_1X_3] &= \beta_{31}E[X_1^2] + \beta_{32}E[X_1X_2] + E[X_1\varepsilon_3] \\ &= \beta_{31} + \beta_{32}\beta_{21} \end{aligned}$$

を X_1 から X_3 への**総合効果**という。

対応する DAG は以下の通りである。



X_3 の構造方程式における X_1 の係数 β_{31} を**直接効果**という。また、 $X_1 \rightarrow X_2 \rightarrow X_3$ の有向道によって得られた $\beta_{32}\beta_{21}$ を**間接効果**という。

より一般的に、構造方程式が以下で与えられるとする。

$$\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$$

$$\begin{cases} X_1 = \varepsilon_1 \\ X_2 = \beta_{21}X_1 + \varepsilon_2 \\ \vdots \\ X_m = \beta_{m,m-1}X_{m-1} + \varepsilon_m \end{cases}$$

このとき、

$$E[X_1X_m] = \beta_{m,m-1} \cdot \beta_{m-1,m-2} \cdots \beta_{21}$$

となり、これは X_1 から X_m への間接効果である。総合効果こそ因果効果の大きさである。

定義 2.4：総合効果

構造方程式

$$\begin{aligned} e &\sim \mathcal{N}(0, I_n) \\ X &= BX + e \end{aligned}$$

について、 $n \times n$ 行列 A を

$$A = (I - B)^{-1}$$

とおいたときの A の (j, i) 成分 a_{ji} を X_i から X_j への**総合効果**という。

定義 2.4 の解釈は総合効果の本質を与える。まず、 B は狭義下三角行列であるから冪零性により、

$$(I - B)^{-1} = I + B + B^2 + \cdots + B^{n-1}$$

である. ここで $i < j$ として B^k の (j, i) 成分 $b_{ji}^{(k)}$ に注目すると,

$$b_{ji}^{(k)} = \sum_{l_{k-1}=1}^n \cdots \sum_{l_1=1}^n \beta_{j,l_{k-1}} \beta_{l_{k-1},l_{k-2}} \cdots \beta_{l_1,i}$$

となる. B は狭義下三角行列であるため,

$$b_{ji}^{(k)} = \sum_{i < l_1 < \cdots < l_{k-1} < j} \beta_{j,l_{k-1}} \beta_{l_{k-1},l_{k-2}} \cdots \beta_{l_1,i}$$

さて, 各 $\beta_{j,l_{k-1}} \cdots \beta_{l_1,i}$ が 0 でない値を持つためには, 任意の β_{l_{m-1},l_m} が 0 でないことが条件となる. これは, 対応する DAG において,

$$X_i \rightarrow X_{l_1} \rightarrow \cdots \rightarrow X_{l_{k-1}} \rightarrow X_j$$

という長さ $k+1$ の有向道が存在することに等しい. すなわち, $b_{ji}^{(k)}$ は X_i から X_j への長さ k の有向道^{*1}によって得られる間接効果の和である. したがって,

$$(I - B)^{-1} = I + B + \cdots + B^{n-1}$$

の (j, i) 成分は, 長さ 1 から n の有向道によって得られる X_i から X_j への間接効果の和, つまり総合効果に等しい.

定義 2.5 : 交絡効果

構造方程式

$$\begin{aligned} e &\sim \mathcal{N}(0, I_n) \\ X &= BX + e \end{aligned}$$

において, $A = (I - B)^{-1}$ としたときに,

$$C = AA^\top - (A + A^\top) + I$$

の (j, i) 成分 c_{ji} を X_i と X_j の交絡効果という.

定義 2.5^{*2}を解釈しよう. まず,

$$X = (I - B)^{-1}e = Ae$$

より X の分散共分散行列は,

$$\begin{aligned} E[XX^\top] &= E[(Ae)(Ae)^\top] \\ &= AE[ee^\top]A^\top \\ &= AA^\top \end{aligned}$$

である. $i < j$ として, c_{ji} は X_i と X_j の共分散から, X_i から X_j への総合効果を引いたものである. ここで, $A = (a_{ij})_{i,j=1}^n$ とおくと,

$$\begin{aligned} c_{ji} &= \sum_{k=1}^n a_{jk}a_{ik} - a_{ji} \\ &= \sum_{k=1}^i a_{jk}a_{ik} - a_{ji} \\ &= \sum_{k=1}^{i-1} a_{jk}a_{ik} \end{aligned}$$

^{*1} 第 3 章参照

^{*2} これは一般的な用語ではないことに注意されたい

ここで、各 k について、 $a_{jk}a_{ik}$ は、 X_k から X_i への総合効果と X_k から X_j への総合効果の積である。これが 0 でないときは、 X_k から X_i への有向道が存在するかつ X_k から X_j への有向道が存在する場合 (図 7) である。これは、 X_i と X_j が共通の祖先を持つことを意味する^{*3}。これは、例 2.2 の擬似相関の概念を包含する概念である。




図 7 交絡効果

最後にパス係数の推定について少し触れよう。これまでは誤差項のパラメータは固定されていたが、推定論に関しては誤差項のパラメータも同時に推定する。

命題 2.6：パス係数の推定

次の構造方程式を考える。

$$\varepsilon_1, \dots, \varepsilon_n \sim \mathcal{N}(\mu, \Psi)$$

$$\mu = (\mu_1, \dots, \mu_n), \quad \Psi = \begin{pmatrix} \sigma_1^2 & 0 & & \\ & \sigma_2^2 & & \\ & & \ddots & \\ 0 & & & \sigma_n^2 \end{pmatrix}$$

$$X = BX + e$$

B の非ゼロ成分を β とおいて、 $\theta = (\beta, \sigma_1^2, \dots, \sigma_n^2)$ とする。さらに、

$$\Sigma(\theta) = (I - B)^{-1} \Psi (I - B)^{-\top}$$

とおいたときに、 θ の最尤推定量 $\hat{\theta}$ は

$$f(\theta) = \text{tr}(\Sigma^{-1}(\theta)S) - \log(|\Sigma^{-1}(\theta)S|) - n$$

を最小にする $\hat{\theta}$ として与えられる。ただし、 S は標本分散共分散行列である。

Proof. まず、

$$X = (I - B)^{-1}e$$

より、 $X \sim \mathcal{N}((I - B)^{-1}\mu, (I - B)^{-1}\Psi(I - B)^{-\top})$ である。ここで、標本 $x_1, \dots, x_N$ が与えられたとする。

^{*3} 正確にはグラフ構造に対する忠実性の仮定が必要である

対数尤度関数は,

$$\begin{aligned}
-\log L(\theta) &= \frac{N}{2} \log(2\pi)^n |\Sigma(\theta)| + \frac{1}{2} \sum_{i=1}^N (x_i - \mu)^\top \Sigma^{-1}(\theta) (x_i - \mu) \\
&= \frac{nN}{2} \log 2\pi - \log |\Sigma(\theta)|^{-1} + \frac{N}{2} \text{tr} \left(\Sigma^{-1}(\theta) \cdot \frac{1}{N} \sum_{i=1}^N (x_i - \mu)(x_i - \mu)^\top \right) \\
&= \frac{nN}{2} \log 2\pi - \frac{N}{2} \log |\Sigma^{-1}(\theta)| + \frac{N}{2} \text{tr}(\Sigma^{-1}(\theta)S)
\end{aligned}$$

ゆえに, 最尤推定量 $\hat{\theta}$ は,

$$-\log |\Sigma^{-1}(\theta)| + \text{tr}(\Sigma^{-1}(\theta)S)$$

を最小化する θ として求められる. ここで, パラメータに関係ない項を加えて,

$$\begin{aligned}
f(\theta) &= \{-\log |\Sigma^{-1}(\theta)| + \text{tr}(\Sigma^{-1}(\theta)S)\} - \log |S| - n \\
&= \text{tr}(\Sigma^{-1}(\theta)S) - \log |\Sigma^{-1}(\theta)S| - n
\end{aligned}$$

を最小化する θ が最尤推定量である. □

例 2.7 :

1.2 で考えた構造方程式において最尤法でパラメータを推定する. 以下に構造方程式の再掲と, 最尤法によるパス係数の推定の結果を表 2 に記載する.

$$\begin{aligned}
\varepsilon_X, \varepsilon_Y, \varepsilon_1, \dots, \varepsilon_6 &\stackrel{\text{i.i.d.}}{\sim} N(0, 1) \\
X &= 0.6Z_1 + 0.6Z_5 + \varepsilon_X \\
Y &= X + 0.6Z_2 + 0.6Z_3 + 0.6Z_6 + \varepsilon_Y \\
Z_1 &= 0.6Z_2 + \varepsilon_1 \\
Z_2 &= \varepsilon_2 \\
Z_3 &= 0.5X + \varepsilon_3 \\
Z_4 &= 0.7X + 0.7Y + \varepsilon_4 \\
Z_5 &= \varepsilon_5 \\
Z_6 &= \varepsilon_6
\end{aligned}$$

表 2 推定結果の要約

結果	関係	原因	推定値
Z1	←	Z2	0.589887
X	←	Z1	0.601150
X	←	Z5	0.596700
Z3	←	X	0.486784
Y	←	X	1.007328
Y	←	Z2	0.581893
Y	←	Z3	0.597675
Y	←	Z6	0.600582
Z4	←	X	0.707937
Z4	←	Y	0.698095

3 DAG

定義 3.1：有向グラフ

1. 有限集合 V と $V \times V$ の部分集合 E の組 (V, E) を (有限) グラフ, V の要素を**頂点**, E の要素を**辺**という.
2. $(X_i, X_j) \in E$ かつ $(X_j, X_i) \notin E$ であるとき, X_i から X_j へ矢線を引く. 一方で, $(X_i, X_j), (X_j, X_i) \in E$ のとき, X_i と X_j の間に向きのない辺を引く.
3. すべての辺が向きのある辺のとき, G を**有向グラフ**という.




図 8 有向グラフ




図 9 無向グラフ

定義 3.2：DAG

$V = \{X_1, \dots, X_n\}$, $E \subset V \times V$, $G = (V, E)$ を有向グラフとする.

1. X_i から X_j への矢線が存在するとき, X_i は X_j の**親**であるといい, X_j は X_i の**子**であるという. また,

$$pa(X_j) = \{X \in V \mid X \text{ は } X_j \text{ の親}\}$$

と定義する.

2. 頂点の列 $\{Y_i\}_{i=1}^m$ で, 各 i について, Y_i から Y_{i+1} または Y_{i+1} から Y_i への矢線が存在するとき, $\{Y_i\}_{i=1}^m$ を長さ m の**道**という. とくに, Y_i から Y_{i+1} への矢線のみが存在する場合, $\{Y_i\}_{i=1}^m$ を**有向道**という.
3. ある有向道 $\{Y_i\}_{i=1}^m$ が存在して, $Y_1 = Y_m$ となるとき, グラフ G を**巡回グラフ**という. 巡回グラフでない有向グラフを**非巡回有向グラフ**という. 以下, 非巡回有向グラフを **DAG** と表記する.




図 10 巡回なし




図 11 巡回あり


定義 3.3：子孫・先祖・合流点

$V = \{X_1, \dots, X_n\}$, $E \subset V \times V$, $G = (V, E)$ は DAG であるとする.

1. 頂点 X_i, X_j について, 有向道 $\{Y_i\}_{i=1}^m, Y_1 = X_i, Y_m = X_j$ が存在するとき, X_i は X_j の**先祖**であるといひ, X_j は X_i の**子孫**であるといひ. X_i のすべての先祖を $an(X_i)$, すべての子孫を $de(X_i)$ で表す.
2. すべての頂点から X_i と X_i の子孫を除いた頂点の部分集合を $nd(X_i)$ と書き, $nd(X_i)$ の要素を X_i の**非子孫**といひ.
3. 長さ m の道 $\{Y_i\}_{i=1}^m$ について, $X_{j-1} \rightarrow X_j$ への矢線が存在し, かつ $X_{j+1} \rightarrow X_j$ への矢線が存在するとき, X_j を**合流点 (Collider)** といひ. とくに, X_{j-1} と X_{j+1} の間に辺が存在しないとき, X_j を**V 字合流点**といひ.

例 3.4：子孫・非子孫・合流点

次の DAG を考える.



1. X_1 の子孫は? $\Rightarrow \{X_2, X_3, X_4, X_5, X_6, X_7\}$
2. X_4 の非子孫は? $\Rightarrow \{X_1, X_2\}$
3. 合流点は? $\Rightarrow \{X_3, X_5\}$

定義 3.5：部分グラフ

$G = (V, E)$ をグラフとして, V の部分集合 U と

$$E_U = \{(X_i, X_j) \in E \mid X_i, X_j \in U\}$$

を定める. このとき, $G_U = (U, E_U)$ はグラフであり, G_U を U が生成する G の**部分グラフ**であるといひ.

命題 3.6：

G が DAG であれば, 部分グラフ G' も DAG である.

Proof. 有向グラフであることと巡回がないことを証明すればよい.

- **有向グラフであること**：もし $(X_i, X_j) \in E', (X_j, X_i) \in E'$ であれば, $(X_i, X_j) \in E, (X_j, X_i) \in E$ となり, これは G が有向グラフであることに矛盾する.
- **非巡回であること**： G' が巡回グラフであるとすれば, 有向道 $\{Y_i\}_{i=1}^m$ が存在する. ここで, 各 i について $Y_i \in V' \subset V$ かつ $(Y_i, Y_{i+1}) \in E' \subset E$ より, $\{Y_i\}_{i=1}^m$ は G の有向道でもあるが, これは G が非巡回であることに矛盾する.

□

定義 3.7：祖先集合

DAG $G = (V, E)$ の頂点の部分集合 U が次の条件を満たすとき, U を祖先集合という.

$$X \in U \Rightarrow pa(X) \subset U$$

命題 3.8：

$V = \{X_1, \dots, X_n\}$, $G = (V, E)$ を DAG とする. 任意の頂点 $X_i \in V$ について, $nd(X_i), nd(X_i) \cup \{X_i\}$ は祖先集合である.

Proof. 任意の頂点 $X_j \in nd(X_i)$ について, X_j から X_i への有向道が存在しない. したがって, X_j の任意の親から X_i への有向道は存在しないため, $pa(X_j) \subset nd(X_i)$. つまり, $nd(X_i)$ は祖先集合である. さらに, 非子孫の定義により X_i の親もすべて $nd(X_i)$ に属する. ゆえに, $nd(X_i) \cup \{X_i\}$ は祖先集合である. $\square$

定義 3.9：隣接行列

$G = (V, E)$ をグラフ, $V = \{X_1, \dots, X_n\}$ とする. $n \times n$ 行列 A を

$$a_{ij} = \begin{cases} 1 & (X_j, X_i) \in E \\ 0 & (X_j, X_i) \notin E \end{cases}$$

として, $A = (a_{ij})_{i,j=1}^n$ で定義する. この A をグラフ G の隣接行列という.

とくに, G が DAG である場合, 隣接行列は冪零行列である. これを証明するために, いくつかの補題を準備しよう.

命題 3.10：トポロジカルソート

$G = (V, E)$ を DAG, $V = \{X_1, \dots, X_n\} \neq \emptyset$ とする. このとき, $X_1, \dots, X_n$ の順序を替えた $Y_1, \dots, Y_n$ であって,

$$(Y_i, Y_j) \in E \Rightarrow i < j$$

となるようにできる.

Proof. まず, $pa(X_k) = \emptyset$ となる頂点 X_k が存在することを証明する.

任意の頂点 X_i について $pa(X_i) \neq \emptyset$ と仮定する. $Z_1 \in V$ として, $pa(Z_1) \neq \emptyset$ より $(Z_2, Z_1) \in E$ となる $Z_2 \in V$ が存在. 同様に $pa(Z_2) \neq \emptyset$ より $(Z_3, Z_2) \in E$ となる $Z_3 \in V$ が存在. これを繰り返すことで, 有向道 $\{Z_i\}_{i=1}^{n+1}$ が存在する. 一方で, V の要素数は n であったから,

$$Z_{i_1} = Z_{i_2}$$

となる $i_1, i_2 \in \{1, \dots, n+1\}$ が存在する. これは G が非巡回であることに矛盾する.

さて, V の要素数の帰納法によって補題を示す. このような規則でグラフの頂点の添字を付け替えることをトポロジカルソートという.

- $n = 1$ のとき, V は補題を満たす.
- $n = k$ のとき, V は補題を満たすと仮定する.
- $n = k + 1$ のとき, $G = (V, E)$ は DAG であるから, $pa(X_k) = \emptyset$ となる $X_k \in V$ が存在. このとき, $V' = V \setminus \{X_k\}$, $E' = \{(X_i, X_j) \in E \mid X_i \neq X_k \text{ かつ } X_j \neq X_k\}$ とすれば, $G' = (V', E')$ は G の部分グラフである. G が DAG であったから G' も DAG であって, 要素数が k である. ゆえに, $X_k = Y_1$ として, V' をトポロジカルソートして $\{Y_i\}_{i=2}^{k+1}$ と並べ替えれば, $\{Y_i\}_{i=1}^{k+1}$ はトポロジカルソートされた頂点集合となる.

$\square$

定理 3.11 :

グラフ G が DAG である場合, 隣接行列 A は狭義下三角行列に相似である.

Proof. $V = \{X_1, \dots, X_n\}$ とする. $\{Y_i\}_{i=1}^n$ はトポロジカルソートされたものであるとする. $Y_1, \dots, Y_n$ は $X_1, \dots, X_n$ の並べ替えであるから, $Y_1 = X_{\pi(1)}, \dots, Y_n = X_{\pi(n)}$ となるような n 次対称群 S_n の元 σ が存在する. ここで, $P = (e_{\sigma(1)}, \dots, e_{\sigma(n)})$ とおく. つまり, $P = (p_{ij})_{i,j=1}^n$ とおくと,

$$p_{ij} = \begin{cases} 1 & (j = \sigma(i)) \\ 0 & (\text{otherwise}) \end{cases}$$

ここで, $PAP^\top$ の (i, j) 成分を a'_{ij} とおく.

$$\begin{aligned} a'_{ij} &= \sum_{k=1}^n \sum_{l=1}^n p_{ik} a_{kl} p_{jl} \\ &= \sum_{k=1}^n p_{ik} \left(\sum_{l=1}^n a_{kl} p_{jl} \right) \\ &= \sum_{k=1}^n p_{ik} a_{k, \sigma(j)} = a_{\sigma(i), \sigma(j)} \end{aligned}$$

$a_{\sigma(i), \sigma(j)}$ の定義より,

$$\begin{aligned} a_{\sigma(i), \sigma(j)} &= \begin{cases} 1 & (X_{\sigma(j)}, X_{\sigma(i)}) \in E \\ 0 & (\text{otherwise}) \end{cases} \\ &= \begin{cases} 1 & (Y_j, Y_i) \in E \\ 0 & (\text{otherwise}) \end{cases} \end{aligned}$$

ゆえに, $PAP^\top$ は $\{Y_i\}_{i=1}^n$ のグラフの隣接行列 A' に等しい. ここで, $\{Y_i\}_{i=1}^n$ はトポロジカルソートされているため,

$$(Y_j, Y_i) \in E \Rightarrow j < i$$

ゆえに, A' は狭義下三角行列である. したがって, 隣接行列 A は狭義下三角行列に相似である. $\square$

4 ベイジアンネットワーク

定義 4.1：ベイジアンネットワーク

$G = (V, E)$ を DAG (有向非巡回グラフ) として, $V = \{X_1, \dots, X_n\}$ について, 各 X_i は確率変数である. $X_1, \dots, X_n$ の同時確率について,

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i \mid pa(X_i))$$

が成り立つとき, このモデルをベイジアンネットワークという.

命題 4.2：祖先集合におけるベイジアンネットワークの性質

確率変数 $X_1, \dots, X_n$ を頂点集合とした DAG $G = (V, E)$ を考える. このとき, 任意の祖先集合 U , つまり

$$X_i \in U \Rightarrow pa(X_i) \subset U$$

となる V の部分集合について, U によって生成される部分グラフ G_U はベイジアンネットワークである.

Proof. 同時確率は以下のように分解できる.

$$P(X_1, \dots, X_n) = \prod_{X_i \in U} P(X_i \mid pa(X_i)) \cdot \prod_{X_j \notin U} P(X_j \mid pa(X_j))$$

ここで, P を $V \setminus U$ に含まれる確率変数で周辺化する. U は祖先集合であるから,

$$X_i \in U \Rightarrow pa(X_i) \subset U$$

が成り立つ. つまり, 第一項の $\prod_{X_i \in U} P(X_i \mid pa(X_i))$ は $V \setminus U$ に含まれる確率変数を含まない. ゆえに,

$$\begin{aligned} P(U) &= \sum_{V \setminus U} P(X_1, \dots, X_n) \\ &= \prod_{X_i \in U} P(X_i \mid pa(X_i)) \cdot \sum_{V \setminus U} \prod_{X_j \notin U} P(X_j \mid pa(X_j)) \end{aligned}$$

ここで, $V \setminus U$ の要素をトポロジカルソートしたものを $\{Y_i\}_{i=1}^m$ とおくと,

$$\begin{aligned} \sum_{V \setminus U} \prod_{X_j \notin U} P(X_j \mid pa(X_j)) &= \sum_{Y_1, \dots, Y_m} \prod_{i=1}^m P(Y_i \mid pa(Y_i)) \\ &= \sum_{Y_1, \dots, Y_{m-1}} \prod_{i=1}^{m-1} P(Y_i \mid pa(Y_i)) \cdot \sum_{Y_m} P(Y_m \mid pa(Y_m)) \\ &= \sum_{Y_1, \dots, Y_{m-1}} \prod_{i=1}^{m-1} P(Y_i \mid pa(Y_i)) \cdot 1 \\ &= \dots = 1 \end{aligned}$$

したがって,

$$P(U) = \prod_{X_i \in U} P(X_i \mid pa(X_i))$$

となり, G_U はベイジアンネットワークの定義を満たす. □

ベイジアンネットワークは次の局所マルコフ性で特徴づけられる.

定義 4.3：局所マルコフ性

$V = \{X_1, \dots, X_n\}$ を確率変数の集合として, DAG $G = (V, E)$ を考える. 任意の X_i がその親を与えられたとき, 親以外のすべての非子孫と独立になる, すなわち,

$$X_i \perp nd(X_i) \setminus pa(X_i) \mid pa(X_i)$$

が成り立つとき, これを**局所マルコフ性**という.

命題 4.4：

ベイジアンネットワークは局所マルコフ性を持つ. 逆に局所マルコフ性をもつ確率分布はベイジアンネットワークである.

Proof. まず, ベイジアンネットワークが局所マルコフ性を持つことを示す. 命題 3.8 により, $nd(X_i) \cup \{X_i\}$ は祖先集合であるから, 命題 4.2 より $G_{nd(X_i) \cup \{X_i\}}$ はベイジアンネットワークである. このとき, 同時確率が次のように分解できる.

$$\begin{aligned} P(nd(X_i) \cup \{X_i\}) &= \prod_{X_j \in nd(X_i) \cup \{X_i\}} P(X_j \mid pa(X_j)) \\ P(nd(X_i)) &= \prod_{X_j \in nd(X_i)} P(X_j \mid pa(X_j)) \end{aligned}$$

よって,

$$\begin{aligned} P(X_i \mid nd(X_i)) &= \frac{P(X_i, nd(X_i))}{P(nd(X_i))} \\ &= \frac{\prod_{X_j \in nd(X_i) \cup \{X_i\}} P(X_j \mid pa(X_j))}{\prod_{X_j \in nd(X_i)} P(X_j \mid pa(X_j))} \\ &= P(X_i \mid pa(X_i)) \end{aligned}$$

が成り立つ. ゆえに,

$$\begin{aligned} P(X_i, nd(X_i) \setminus pa(X_i) \mid pa(X_i)) &= \frac{P(X_i, nd(X_i))}{P(pa(X_i))} \\ &= \frac{P(X_i \mid nd(X_i)) \cdot P(nd(X_i))}{P(pa(X_i))} \\ &= \frac{P(X_i \mid pa(X_i)) \cdot P(nd(X_i))}{P(pa(X_i))} \\ &= P(X_i \mid pa(X_i)) \cdot P(nd(X_i) \mid pa(X_i)) \end{aligned}$$

したがって, 局所マルコフ性が証明される. 次に, 局所マルコフ性をもつ確率分布がベイジアンネットワークであることを示す. $V = \{X_1, \dots, X_n\}$ について, V の要素をトポロジカルソートして $Y_1, \dots, Y_n$ と並べ替える. 一般的に次の式が成り立つ.

$$\begin{aligned} P(Y_1, \dots, Y_n) &= P(Y_1) \cdot P(Y_2 \mid Y_1) \cdots P(Y_n \mid Y_1, \dots, Y_{n-1}) \\ &= \prod_{i=1}^n P(Y_i \mid Y_1, \dots, Y_{i-1}) \end{aligned}$$

ここで, $Y_1, \dots, Y_n$ はトポロジカルソートされているため $\{Y_1, \dots, Y_{i-1}\} \subset nd(Y_i)$ が成り立つ. ゆえに, 局所マルコフ性より,

$$P(Y_i \mid Y_1, \dots, Y_{i-1}) = P(Y_i \mid pa(Y_i))$$

が成り立つ. したがって,

$$\begin{aligned} P(Y_1, \dots, Y_n) &= \prod_{i=1}^n P(Y_i | Y_1, \dots, Y_{i-1}) \\ &= \prod_{i=1}^n P(Y_i | pa(Y_i)) \end{aligned}$$

したがって, G はベイジアンネットワークである. □

局所マルコフ性は実質的に,

$$P(X_i | nd(X_i)) = P(X_i | pa(X_i))$$

を要請していることが分かる. これは, 自分の非子孫, つまり「前の情報」による条件付き確率は, 親で条件を付けるのと変わらないことを要求している.

定義 4.5: 有向分離 (d-separation)

$V = \{X_1, \dots, X_n\}$, $G = (V, E)$ として, ベイジアンネットワークを考える. 頂点 X_i, X_j を結ぶ道 p を考える. V の部分集合 S が次の I, II の一方の条件を満たすとき, S は道 p を**ブロックする**という.

- I. p が $X_\alpha \rightarrow X_\beta \rightarrow X_\gamma$ または $X_\alpha \leftarrow X_\beta \rightarrow X_\gamma$ という経路を含み, かつ S は X_β を含む.
- II. p が $X_\alpha \rightarrow X_\beta \leftarrow X_\gamma$ という経路 (合流点) を含み, かつ S は X_β および任意の X_β の子孫を含まない.

X_i, X_j を結ぶすべての道が V の部分集合 S によってブロックされているとき, S は X_i, X_j を**有向分離**するという.

定理 4.6: 大域マルコフ性


ベイジアンネットワーク $V = \{X_1, \dots, X_n\}$, $G = (V, E)$ において, X_i, X_j が $S \subset V$ によって有向分離されているとき,

$$X_i \perp X_j \mid S$$

が成り立つ.

例 4.7:

次の DAG を考える.



X_1 と X_5 を有向分離する S を考える. X_1 と X_5 の道は:

- $p_1 : X_1 \rightarrow X_2 \rightarrow X_5$
- $p_2 : X_1 \leftarrow X_3 \leftarrow X_4 \rightarrow X_5$
- $p_3 : X_1 \leftarrow X_3 \rightarrow X_2 \rightarrow X_5$
- $p_4 : X_1 \rightarrow X_2 \leftarrow X_3 \leftarrow X_4 \rightarrow X_5$

このとき, S は何か考えよう. まず, p_1 の構造は条件 I の連鎖構造であるから, $X_2 \in S$ でなければならな

い. 一方, p_4 に着目すれば, X_2 は合流点である. ゆえに, S が条件 II を満たすことはない. p_2, p_3, p_4 については条件 I を満たすように S を定める. これらを考慮すれば,

$$S = \{X_2, X_3\}$$

と求められる. ゆえに, 定理 4.6 によれば,

$$X_1 \perp X_5 \mid X_2, X_3$$

が成立する. ここで,

$$P(X_1, X_2, X_3, X_4, X_5) = P(X_1 \mid X_3)P(X_2 \mid X_1, X_3)P(X_3 \mid X_4)P(X_4)P(X_5 \mid X_2, X_4)$$

X_4 で周辺化すると,

$$P(X_1, X_2, X_3, X_5) = P(X_1 \mid X_3)P(X_2 \mid X_1, X_3) \sum_{X_4} P(X_3 \mid X_4)P(X_4)P(X_5 \mid X_2, X_4)$$

ここで,

$$\phi_1(X_1, X_2, X_3) = P(X_1 \mid X_3)P(X_2 \mid X_1, X_3)$$

$$\phi_2(X_5, X_2, X_3) = \sum_{X_4} P(X_3 \mid X_4)P(X_4)P(X_5 \mid X_2, X_4)$$

とおけば,

$$P(X_1, X_2, X_3, X_5) = \phi_1(X_1, X_2, X_3)\phi_2(X_5, X_2, X_3)$$

となり, 条件付き独立性が証明できる.

定理 4.6 はベイジアンネットワークの理論における大定理であり, 証明のためにいくつかの準備を要する.

定義 4.8：無向グラフ

頂点集合 $V = \{X_1, \dots, X_n\}$ とグラフ $G = (V, E)$ において,

$$(X_i, X_j) \in E \Rightarrow (X_j, X_i) \in E$$


が成り立つ, つまり, すべての辺に向きがない辺であるとき, G を**無向グラフ**という.

定義 4.9：完全グラフ・クリーク

頂点集合 $V = \{X_1, \dots, X_n\}$, 無向グラフ $G = (V, E)$ を考える.

1. 任意の頂点 X_i, X_j が辺で結ばれているとき, グラフ G は**完全グラフ**であるという.
2. V の部分集合 C において, C が生成する部分グラフ G_C が完全グラフであるとき, C を**クリーク**という. とくに, $C \subset U$ かつ U がクリークである $U \subset V$ が存在しないとき, C は**極大クリーク**であるという.

例 4.10：



$\{X_1, X_2, X_3\}, \{X_2, X_4, X_5\}$ は極大クリークである.

定義 4.11：道・連結・分離

頂点集合 $V = \{X_1, \dots, X_n\}$, 無向グラフ $G = (V, E)$ を考える.

1. 頂点の列 $\{Y_i\}_{i=1}^m$ において, $(Y_{i-1}, Y_i) \in E$ となるとき, $\{Y_i\}_{i=1}^m$ を長さ m の道という.
2. 頂点 X_i, X_j において, 長さ m の道 $\{Y_i\}_{i=1}^m$ が存在して, $Y_1 = X_i, Y_m = X_j$ となるとき, X_i, X_j は連結しているという. すべての頂点の組が連結しているグラフを連結グラフ, 連結していない頂点の組が存在するグラフを非連結グラフという.
 G の部分集合 U から生成される部分グラフ G_U が連結グラフをなす極大な部分グラフ (任意の $U \subset U'$ について $G_{U'}$ が連結グラフでない) とき, U を連結成分という.
3. S を V の部分集合として, 頂点 X_i と X_j を結ぶ任意の道 p が, S のある要素を含むとき, S は X_i と X_j を分離するという.

定義 4.12：マルコフネットワーク

確率変数 $X_1, \dots, X_n$ を頂点とした $V = \{X_1, \dots, X_n\}$ と無向グラフ $G = (V, E)$ を考える. 2つの辺のない頂点 X_i, X_j が V の部分集合 S によって分離されているとき,

$$X_i \perp X_j \mid S$$

が成立する. この性質を満足するモデルをマルコフネットワークという.

このマルコフネットワークの定義は大域マルコフ性と呼ばれる. マルコフネットワークは次の局所マルコフ性を持つ.

命題 4.13：局所マルコフ性

マルコフネットワーク $V = \{X_1, \dots, X_n\}$, $G = (V, E)$ を考える. $X_i \in V$ に対して,

$$\begin{aligned} bd(X_i) &= \{X_j \in V \mid (X_i, X_j) \in E\} \\ cl(X_i) &= \{X_i\} \cup bd(X_i) \end{aligned}$$

とおく. このとき,

$$X_i \perp V \setminus cl(X_i) \mid bd(X_i)$$

が成り立つ.

Proof. 定義より, $bd(X_i)$ は X_i と $V \setminus cl(X_i)$ の任意の要素を分離する. ゆえに大域マルコフ性より, $X_j \in V \setminus cl(X_i)$ について,

$$X_i \perp X_j \mid bd(X_i).$$

よって示された. □

定理 4.14：

確率変数 $X_1, \dots, X_n$ を頂点とした $V = \{X_1, \dots, X_n\}$ と無向グラフ $G = (V, E)$ を考える. $C_1, \dots, C_l$ をクリークとして,

$$V = \bigcup_{k=1}^l C_k$$

とする. また, 各 C_i の要素を $X^{(k)}$ とおく. 今, $X_1, \dots, X_n$ の同時確率が,

$$P(X_1, \dots, X_n) = \prod_{k=1}^l \phi_k(X^{(k)})$$

と分解できるとする. このとき大域マルコフ性を満たす.

Proof. X_i, X_j を辺がない任意の頂点, S を分離集合とする. さて, 集合 $V \setminus S$ において, X_i を含む連結成分を $C(X_i)$ とおく. さらに

$$D(X_i) = C(X_i) \cup S$$

とおく. 一方,

$$D(X_j) = V \setminus C(X_i)$$

とおく. ここで, G の S に含まれない任意のクリーク C について考える. C は $D(X_i), D(X_j)$ のいずれか一方の部分集合であることを示す. まず C が $D(X_i), D(X_j)$ の少なくとも一方に含まれることを証明しよう.

$C \not\subseteq D(X_i)$ かつ $C \not\subseteq D(X_j)$ と仮定する. このとき, $X_c^{(1)} \notin D(X_i)$ かつ $X_c^{(2)} \notin D(X_j)$ となる元 $X_c^{(i)}, X_c^{(j)} \in C$ が存在する. C はクリークであるから, $X_c^{(1)}$ と $X_c^{(2)}$ の間に辺が存在する. ゆえに, $D^c(X_j) = C(X_i)$ から $X_c^{(2)} \in C(X_i)$ であり, 連結成分の定義より $X_c^{(1)} \in C(X_i)$. これは, $X_i^{(1)} \in D(X_i)$ に矛盾する. 次に, C が $D(X_i), D(X_j)$ の両方に含まれないことを確認しよう. $D(X_i) \cap D(X_j) = S$ と $C \not\subseteq S$ より, C は $D(X_i), D(X_j)$ の両方に含まれることはない. 以上により, C は $D(X_i), D(X_j)$ のいずれか一方の部分集合であることが示された.

ここで,

$$\mathcal{C} = \{C_1, \dots, C_l\}$$

として,

$$\mathcal{C}_i = \{C \in \mathcal{C} \mid C \subseteq S \text{ または } C \subseteq D(X_i)\}$$

$$\mathcal{C}_j = \{C \in \mathcal{C} \mid C \not\subseteq S \text{ かつ } C \subseteq D(X_j)\}$$

とすれば, $\mathcal{C} = \mathcal{C}_i \cup \mathcal{C}_j, \mathcal{C}_i \cap \mathcal{C}_j = \phi$ となる. ここで,

$$\begin{aligned} P(X_1, \dots, X_n) &= \prod_{k=1}^l \phi_k(X^{(k)}) \\ &= \prod_{C_k \in \mathcal{C}_i} \phi_k(X^{(k)}) \cdot \prod_{C_k \in \mathcal{C}_j} \phi_k(X^{(k)}) \end{aligned}$$

さらに,

$$C_k \in \mathcal{C}_i \Rightarrow C_k \cap (D(X_j) \setminus S) = \phi$$

$$C_k \in \mathcal{C}_j \Rightarrow C_k \cap C(X_i) = \phi$$

となるため, $\{X_i, X_j\} \cup S$ 以外で周辺化して,

$$\begin{aligned} \sum_{V \setminus \{X_i, X_j\} \cup S} P(X_1, \dots, X_n) &= \sum_{C(X_i) \setminus \{X_i\}} \sum_{D(X_j) \setminus S \cup \{X_j\}} \prod_{k=1}^l \phi_k(X^{(k)}) \\ &= \sum_{C(X_i) \setminus \{X_i\}} \prod_{C_k \in \mathcal{C}_i} \phi_k(X^{(k)}) \cdot \sum_{D(X_j) \setminus S \cup \{X_j\}} \prod_{C_k \in \mathcal{C}_j} \phi_k(X^{(k)}) \end{aligned}$$

$$\psi_1(X_i, S) = \sum_{C(X_i) \setminus \{X_i\}} \prod_{C_k \in \mathcal{C}_i} \phi_k(X^{(k)})$$

$$\psi_2(X_j, S) = \sum_{D(X_j) \setminus S \cup \{X_j\}} \prod_{C_k \in \mathcal{C}_j} \phi_k(X^{(k)})$$

とおけば,

$$P(X_i, X_j, S) = \psi_1(X_i, S)\psi_2(X_j, S)$$

と分解できて, $X_i \perp X_j \mid S$ が言える. □

さて, 定理 4.14 によってマルコフネットワークにおいても同時確率の分解は, グラフの形が決定づけることが分かるが, ベイジアンネットワークの場合とはギャップがある. 次の無向グラフを考える.

$$X_1 - X_2 - X_3$$

これは, X_2 が X_1, X_3 を分離しているため, 大域マルコフ性により,

$$X_1 \perp X_3 \mid X_2$$

同時確率で表せば,

$$P(X_1, X_2, X_3) = \phi_1(X_1, X_2)\phi_2(X_2, X_3)$$

と分解できることに等しい. 一方で, この無向グラフを有向グラフとして考える場合は 3 通りの矢線の引き方が考えられる.

1. $X_1 \rightarrow X_2 \rightarrow X_3$ または $X_1 \leftarrow X_2 \leftarrow X_3$
2. $X_1 \leftarrow X_2 \rightarrow X_3$
3. $X_1 \rightarrow X_2 \leftarrow X_3$

これらをベイジアンネットワークと見て同時確率を分解すると,

1. $P(X_1, X_2, X_3) = P(X_1)P(X_2 \mid X_1)P(X_3 \mid X_2) = P(X_1, X_2)P(X_3 \mid X_2)$
2. $P(X_1, X_2, X_3) = P(X_1 \mid X_2)P(X_2)P(X_3 \mid X_2) = P(X_1, X_2)P(X_3 \mid X_2)$
3. $P(X_1, X_2, X_3) = P(X_2 \mid X_1, X_3)P(X_1)P(X_3)$

となる. まず興味深いのは, 1, 2 の同時分布はまったく同じである. つまり, データのみから 1, 2 のどちらの構造であるかを同定するのは非常に困難である. この難しさは後の因果探索の分野で触れる.

さて, 無向グラフと有向グラフの同時確率が一致したのは 1, 2 の場合である. 3 の構造については, 大域マルコフ性

$$X_1 \perp X_3 \mid X_2$$

が一般に成り立たない. むしろ 3 の場合は,

$$\begin{aligned} P(X_1, X_2, X_3) &= P(X_2 \mid X_1, X_3)P(X_1)P(X_3) \\ &= \frac{P(X_1, X_2, X_3)}{P(X_1, X_3)}P(X_1)P(X_3) \end{aligned}$$

より, $P(X_1, X_3) = P(X_1)P(X_3)$ となり, X_1, X_3 は独立であることが分かる. 合流点においては, 条件を付けることでむしろ独立性が崩れることがある.


合流点の構造をそのまま無向グラフにすると, 条件付き独立性という誤った結論となる. このギャップを埋めるために, **モラル化**という操作を行う.

定義 4.15: モラルグラフ

有向グラフ $G = (V, E)$ に対して, 次のように構成される無向グラフを G のモラルグラフといい, G^m と表す.

1. G^m の頂点集合は V
2. $(X_i, X_j) \in E$ ならば, G^m において X_i と X_j に辺を引く.
3. 有向グラフ G で $(X_i, X_k) \in E$ かつ $(X_j, X_k) \in E$ ならば, G^m において X_i と X_j に辺を引く.

とくに 3 の条件で引かれた辺を**モラルエッジ**という。また、有向グラフ G のモラルグラフ G^m を考えることを G を**モラル化**するという。



定理 4.16：大域マルコフ性とモラルグラフ

頂点集合 $V = \{X_1, \dots, X_n\}$ のベイジアンネットワーク $G = (V, E)$ が与えられているとする。このとき、 G をモラル化した G^m とそのマルコフネットワークについて、 V の部分集合 S が $X_i, X_j \in V$ を分離するとき、ベイジアンネットワーク G において、

$$X_i \perp X_j \mid S$$

が成り立つ。

Proof. ベイジアンネットワークの定義から、同時確率は

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i \mid pa(X_i))$$

と書ける。ここで、 $\{X_i\} \cup pa(X_i)$ について、 X_i と $pa(X_i)$ の各要素には辺があり、モラルグラフの定義により、 $pa(X_i)$ のどの 2 つの要素にも辺が存在するため、 $\{X_i\} \cup pa(X_i)$ はクリークである。ゆえに、同時確率がクリーク毎の要素の関数の積で書けるため、定理 4.14 より、 G^m は大域マルコフ性を持ち、マルコフネットワークとなる。ゆえに、 $X_i, X_j \in V$ を $S \subseteq V$ が分離するとき、

$$X_i \perp X_j \mid S$$

が成り立つ。 □

定理 4.16 の本質は、同時確率 $P(X_1, \dots, X_n)$ が分解できることにある。これにより、より小さい S によって、 X_i と X_j の条件付き独立性が証明される。

係 4.17：

頂点集合 $V = \{X_1, \dots, X_n\}$ のベイジアンネットワーク $G = (V, E)$ が与えられているとする。また、 $X_i, X_j \in V$ と $S \subseteq V$ は互いに排反であるとする。このとき、 $\{X_i\} \cup \{X_j\} \cup S$ を含む最小の祖先集合 $An(\{X_i\} \cup \{X_j\} \cup S)$ を考える。この祖先集合により生成される部分グラフのモラルグラフ $G^m_{An(\{X_i\} \cup \{X_j\} \cup S)}$ において、 S が X_i と X_j を分離するとき、

$$X_i \perp X_j \mid S$$

が成り立つ。

Proof. 命題 4.2 より、 $G_{An(\{X_i\} \cup \{X_j\} \cup S)}$ はベイジアンネットワークであるから、定理 4.16 により大域マルコフ性が証明される。 □

この系 4.17 を構成する S こそ、定義 4.5 で述べた**有向分離**である。

定理 4.18 : Lauritzen(1990)

頂点集合 $V = \{X_1, \dots, X_n\}$ のベイジアンネットワーク $G = (V, E)$ が与えられているとする。頂点 X_i, X_j が $S \subset V$ によって有向分離されているとき、 S は無向グラフ $G_{An(\{X_i, X_j\} \cup S)}^m$ において X_i と X_j を分離する。

Proof. 背理法を用いる。 S は無向グラフ $G_{An(\{X_i, X_j\} \cup S)}^m$ において X_i と X_j を分離していないと仮定する。つまり、ある道 $p = \{Y_k\}_{k=1}^m$ が $G_{An(\{X_i, X_j\} \cup S)}^m$ に存在して、どの Y_k も S の要素でない。 Y_k と Y_{k+1} の辺を e_k ($k = 1, \dots, m-1$) とする。

頂点の列 $\{Z_k\}_{k=1}^l$ を次のようにとる。

1. $Z_1 = Y_1$
2.
 - e_1 がモラルエッジでないとき、 $Z_2 = Y_2$ とする。
 - e_1 がモラルエッジのとき、 Y_1 と Y_2 の G における共通の子 $\gamma \in An(\{X_i\} \cup \{X_j\} \cup S)$ として $Z_2 = \gamma$, $Z_3 = Y_2$ とする。

$e_2, \dots, e_{m-1}$ においても同様に 2 のルールに従って頂点の列 $\{Z_k\}_{k=1}^l$ をとることができる。

$p' = \{Z_k\}_{k=1}^l$ とすると、 $Z_1 = Y_1 = X_i$, $Z_l = Y_m = X_j$ となり、 p' はグラフ G における X_i と X_j の道である。

ここで、道 p' の非合流点はすべて S の要素ではない。ゆえに、 p' は定義 4.5 の条件 I によってブロックされない。特に p' に合流点が存在しない場合、 p' は S によってブロックされない。これは S が X_i と X_j を有向分離することに矛盾する。

さて、すべての Z_k は $An(\{X_i\} \cup \{X_j\} \cup S)$ の元であるから、 p' の任意の合流点 γ について次のいずれかが成り立つ。

- a) $\gamma \in An(S)$
- b) $\gamma \notin An(S)$

a) となる合流点が p' に存在する場合： S は合流点の子孫を含むため、定義 4.5 の条件 II により p' は S によってブロックされない。これは S が X_i と X_j を有向分離することに矛盾する。

p' のすべての合流点が b) の場合：道 p' の合流点を $\gamma_1, \dots, \gamma_u$ とおく。このとき $\gamma_1, \dots, \gamma_u \in An(\{X_i, X_j\})$ である。 $\gamma_1, \dots, \gamma_u$ の中で $An(X_i)$ に属するものの最大番号のものを $\gamma = Z_r$ とおく。

$Z_r \in An(X_i)$ より、 Z_r から $X_i = Z_1$ への有向道 $\{W_k\}_{k=1}^t$ ($W_1 = X_i$, $W_t = Z_r$) が存在する：

$$W_1 \leftarrow W_2 \leftarrow \dots \leftarrow W_t \leftarrow Z_{r+1} \leftarrow \dots \leftarrow Z_l.$$

$W_t = Z_r \notin An(S)$ より $W_1, \dots, W_t \notin S$ である。 Z_r の最大性により、 $Z_{r+1}, \dots, Z_l$ に含まれる合流点はすべて $An(X_j)$ に属する。そのうち最小番号のものを $\gamma' = Z_g$ とおく。 $Z_g \in An(X_j)$ より、 Z_g から $X_j = Z_l$ への有向道 $\{W'_k\}_{k=1}^u$ ($W'_1 = Z_g$, $W'_u = X_j$) が存在する：

$$W_1 \leftarrow \dots \leftarrow W_t \leftarrow Z_{r+1} \leftarrow \dots \leftarrow Z_{g-1} \rightarrow W'_1 \rightarrow \dots \rightarrow W'_u.$$

$W'_1 = Z_g \notin An(S)$ より $W'_1, \dots, W'_u \notin S$ 。また、 $Z_{r+1}, \dots, Z_{g-1}$ は p' の非合流点であるから S に属さない。道 $p'' = W_1, \dots, W_t, Z_{r+1}, \dots, Z_{g-1}, W'_1, \dots, W'_u$ においては、すべての頂点は S に属さず、合流点も存在しない。ゆえに S は道 p'' をブロックしない。

以上のように、 S は X_i と X_j を有向分離することに矛盾する。 □

定理 4.18 は逆も成り立つことが知られている。

定理 4.19 : Lauritzen(1990)

頂点集合 $V = \{X_1, \dots, X_n\}$ のベイジアンネットワーク $G = (V, E)$ が与えられているとする. S が無向グラフ $G_{An(\{X_i, X_j\} \cup S)}^m$ において X_i と X_j を分離するとき, 頂点 X_i, X_j が $S \subset V$ によって有向分離されている.

Proof. 背理法を用いる. 頂点集合 S が X_i, X_j を有向分離しないとき, つまり X_i, X_j の道 $p = \{Y_k\}_{k=1}^m$ が存在して, p は S によってブロックされていない. p に合流点が存在しなければ, p の任意の頂点は S に含まれず, S は X_i と X_j を分離しない.

このとき, p の任意の合流点 γ について, γ または γ の子孫が S に含まれる. ゆえに, $\gamma \in An(S)$. さらに, $An(\gamma) \subset An(S)$ である. したがって, $p \subset An(S \cup \{X_i, X_j\})$. さて, この p について, 合流点以外は S の元ではない. さらに, 合流点については, モラル化することにより, 合流点を含まない $G_{An(S \cup \{X_i, X_j\})}^m$ の道 p' を構成できる. $\square$

さて, 以上の準備の下で定理 4.6 を証明しよう.

定理 4.6 : 大域マルコフ性

ベイジアンネットワーク $V = \{X_1, \dots, X_n\}$, $G = (V, E)$ において, X_i, X_j が $S \subset V$ によって有向分離されているとき,

$$X_i \perp X_j \mid S$$

が成り立つ.

Proof. 定理 4.18, 4.19 により, S は無向グラフ $G_{An(S \cup \{X_i, X_j\})}^m$ を (そのときに限り) 分離する. ゆえに, 系 4.17 により,

$$X_i \perp X_j \mid S$$

が成り立つ. $\square$

5 介入・因果効果

定義 5.1：構造的因果モデル

$X_1, \dots, X_n$ を確率変数, $V = \{X_1, \dots, X_n\}$ を頂点集合とした DAG $G = (V, E)$ を考える. 各 X_i が可測関数 f_i と誤差変数 ε_i を用いて,

$$X_i = f_i(pa(X_i), \varepsilon_i)$$

と記述されたとする. このとき, G を**構造的因果モデル**という. ただし, 誤差変数 ε_i は外生的, つまり DAG $G' = (V \cup \{\varepsilon_1, \dots, \varepsilon_n\}, E \cup (\bigcup_{k=1}^n \{(\varepsilon_k, X_k)\}))$ とおいたときに,

1. 各 i について, $pa(\varepsilon_i) = \emptyset$
2. $i \neq j$ ならば, $\varepsilon_i \perp \varepsilon_j$
3. $X_j \in nd(X_i)$ ならば, $\varepsilon_i \perp X_j$

を仮定する.

命題 5.2：

構造的因果モデルはベイジアンネットワークである.

Proof. まず, $V' = \{X_1, \dots, X_n, \varepsilon_1, \dots, \varepsilon_n\}$ として DAG G' を考える. このとき, $\varepsilon_1, \dots, \varepsilon_n$ は親を持たず, 各 i について X_i は ε_i の子であることに注意する.

ここで, 任意の X_i とその非子孫 $nd(X_i)$ の任意の要素 U について,

$$X_i \perp U \mid pa(X_i), \varepsilon_i$$

が成り立つ. ここで $pa(X_i)$ はグラフ G における親であることに注意する. 実際に,

$$X_i = f_i(pa(X_i), \varepsilon_i)$$

であるため, $X_i \mid pa(X_i), \varepsilon_i$ は定数（決定論的に決まる）である. ゆえに,

$$X_i \perp U \mid pa(X_i), \varepsilon_i$$

したがって, G' は局所マルコフ性を持ち, ベイジアンネットワークである. $pa(\varepsilon_i) = \emptyset$ に注意して,

$$P(X_1, \dots, X_n, \varepsilon_1, \dots, \varepsilon_n) = \prod_{i=1}^n P(X_i \mid pa(X_i), \varepsilon_i) P(\varepsilon_i)$$

さて, 今 $X_1, \dots, X_n$ をトポロジカルソートして, ε の番号と対応させたものとする.

$$\begin{aligned} P(X_1, \dots, X_n) &= \sum_{\varepsilon_1, \dots, \varepsilon_n} P(X_1, \dots, X_n, \varepsilon_1, \dots, \varepsilon_n) \\ &= \sum_{\varepsilon_1, \dots, \varepsilon_n} \prod_{i=1}^n P(X_i \mid pa(X_i), \varepsilon_i) P(\varepsilon_i) \\ &= \sum_{\varepsilon_1, \dots, \varepsilon_n} \prod_{i=1}^n P(X_i, \varepsilon_i \mid pa(X_i)) \\ &= \sum_{\varepsilon_1, \dots, \varepsilon_{n-1}} \prod_{i=1}^{n-1} P(X_i, \varepsilon_i \mid pa(X_i)) \cdot \sum_{\varepsilon_n} P(X_n, \varepsilon_n \mid pa(X_n)) \\ &= \dots \\ &= \prod_{i=1}^n P(X_i \mid pa(X_i)) \end{aligned}$$

となり、 G はベイジアンネットワークの定義を満たす。 □

定義 5.3：矢線の削除

DAG $G = (V, E)$ と $X_i \in V$ を考える。

X_i に入る矢線をすべて消去した DAG を $G_{\overline{X_i}}$, X_i から出る矢線をすべて消去した DAG を $G_{\underline{X_i}}$ と書く。

より一般に、 $X_{i_1}, \dots, X_{i_l} \in V$ について、 $X_{i_1}, \dots, X_{i_j}$ に入る矢線をすべて消去し、 $X_{i_{j+1}}, \dots, X_{i_l}$ から出る矢線をすべて消去した DAG を

$$G_{\overline{X_{i_1} \dots X_{i_j}} \underline{X_{i_{j+1}} \dots X_{i_l}}}$$

と書く。

定義 5.4：介入

DAG $G = (V, E)$, $V = \{X_1, \dots, X_n\}$ で、 G は構造的因果モデル、すなわち、各 $j \in \{1, \dots, n\}$ について、 X_j の親 $pa(X_j)$ と誤差変数 ε_j , 関数 f_j を用いて、

$$X_j = f_j(pa(X_j), \varepsilon_j)$$

と記述されるとする。このとき、ある i について、定数 x_i を用いて、

$$X_i = x_i$$

と書き換える。この新しいメカニズムによって記述される構造的因果モデル $G_{\overline{X_i}}$ に基づく確率を

$$P(X_1, \dots, X_n \mid do(X_i = x_i))$$

で表し、この操作を X_i についての介入という。また、この確率を介入後分布という。

さて、この介入後分布 $P(X_1, \dots, X_n \mid do(X_i = x_i))$ は定理 5.2 から G におけるベイジアンネットワークであることが保証されているため、同時確率は次のように分解できる。

$$\begin{aligned} P(X_1, \dots, X_n \mid do(X_i = x_i)) &= \prod_{j=1}^n P(X_j \mid pa(X_j)) \\ &= \prod_{j=1, j \neq i}^n P(X_j \mid pa(X_j)) \cdot P(X_i \mid pa(X_i)) \end{aligned}$$

ここで、 $X_i = x_i$ より、 $X_i \perp pa(X_i)$ であって、

$$P(X_i \mid pa(X_i)) = P(X_i) = \delta(x_i) = \begin{cases} 1 & (X_i = x_i) \\ 0 & (X_i \neq x_i) \end{cases}$$

となるから、

$$\begin{aligned} P(X_1, \dots, X_n \mid do(X_i = x_i)) &= \prod_{j=1, j \neq i}^n P(X_j \mid pa(X_j)) \cdot \delta(x_i) \\ &= \begin{cases} \prod_{j=1, j \neq i}^n P(X_j \mid pa(X_j)) & (X_i = x_i) \\ 0 & (X_i \neq x_i) \end{cases} \end{aligned}$$


と書ける。ゆえに、 $P(X_1, \dots, X_n \mid do(X_i = x_i))$ は $G_{\overline{X_i}}$ におけるベイジアンネットワークであることが分かる。

ここで、介入前と介入後の構造的因果モデルにおける確率変数は異なる確率変数であることに注意する。なお、 X_i の非子孫については、生成過程に影響を与えず、同一の確率変数と考えてよい。

では G と $G_{\overline{X_i}}$ をグラフとして比較してみよう。 $G_{\overline{X_i}}$ は、 X_i と $pa(X_i)$ が独立、つまり、グラフ上において、 $pa(X_i)$ から X_i への矢線をすべて排除した形になる。

例 5.5 :

次の DAG から生成される構造的因果モデルを考える。



介入 $do(X_1 = x_1)$ を行った $G_{\overline{X_1}}$ を考える。 G と $G_{\overline{X_1}}$ を比較すれば、 $X_2 \rightarrow X_1$ の矢線が消えていることが分かる。つまり、 $G_{\overline{X_1}}$ の分布においては、 X_1 と X_4 に共通の祖先は存在せず、交絡は存在しないことが分かる。

次に因果効果の定義を与えよう。

定義 5.6 : 平均因果効果

DAG $G = (V, E)$ は構造的因果モデルとする。このとき、 $Y, X \in V$ について、 $X = x_1$ から $X = x_2$ に介入したときの Y への平均因果効果を

$$E[Y \mid do(X = x_1)] - E[Y \mid do(X = x_2)]$$

で定義する。ただし、

$$E[Y \mid do(X = x)] = \sum_y Y P(Y \mid do(X = x))$$

である。とくに、 X が二値 $\{0, 1\}$ をとる確率変数であるとき、

$$E[Y \mid do(X = 1)] - E[Y \mid do(X = 0)]$$

を平均処置効果 (ATE) という。

定義 5.7 : 同時介入

DAG $G = (V, E)$, $V = \{X_1, \dots, X_n\}$ で、 G は構造的因果モデル、すなわち、各 $j \in \{1, \dots, n\}$ について、 X_j の親 $pa(X_j)$ と誤差変数 ε_j 、関数 f_j を用いて、

$$X_j = f_j(pa(X_j), \varepsilon_j)$$

と記述されるとする。このとき、ある $i_1, \dots, i_k$ について、定数 $x_{i_1}, \dots, x_{i_k}$ を用いて、

$$X_{i_1} = x_{i_1}, \dots, X_{i_k} = x_{i_k}$$

と書き換える。この新しいメカニズムによって記述される構造的因果モデルに基づく確率を

$$P(X_1, \dots, X_n \mid do(X_{i_1} = x_{i_1}), \dots, do(X_{i_k} = x_{i_k}))$$

で表し、この操作を $X_{i_1}, \dots, X_{i_k}$ についての同時介入という。このとき、同時確率は、

$$\begin{aligned} P(X_1, \dots, X_n \mid do(X_{i_1} = x_{i_1}), \dots, do(X_{i_k} = x_{i_k})) \\ = \begin{cases} \prod_{j \notin \{i_1, \dots, i_k\}} P(X_j \mid pa(X_j)) & (X_{i_1} = x_{i_1}, \dots, X_{i_k} = x_{i_k}) \\ 0 & (\text{otherwise}) \end{cases} \end{aligned}$$

となる。

定義 5.8：変数としての介入

DAG $G = (V, E)$, $V = \{X_1, \dots, X_n\}$ で、 G は構造的因果モデル、すなわち、各 $j \in \{1, \dots, n\}$ について、 X_j の親 $pa(X_j)$ と誤差変数 ε_j 、関数 f_j を用いて、

$$X_j = f_j(pa(X_j), \varepsilon_j)$$

と記述されるとする。このとき、 $\{idle, x_i\}$ の値をとる外生変数 F_i を用いて、

$$\begin{aligned} X_i &= \hat{f}_i(pa(X_i), \varepsilon_i, F_i) \\ &= \begin{cases} x_i & (F_i = x_i) \\ f_i(pa(X_i), \varepsilon_i) & (F_i = idle) \end{cases} \end{aligned}$$

と書き換える。 $V' = \{X_1, \dots, X_n, F_i\}$, $E' = E \cup \{(F_i, X_i)\}$ としたときに、 $G' = (V', E')$ は構造的因果モデルであり、この G' を**拡張ネットワーク**という。

なお、同時介入についても拡張ネットワークは同様に定義できる。

G' は定義から、 $F_i = idle$ であれば G に、 $F_i = x_i$ であれば $G_{\overline{X_i}}$ に等しくなる。つまり、

$$P(X_1, \dots, X_n \mid do(X_i = x_i)) = P(X_1, \dots, X_n \mid F_i = x_i)$$

となる。

さて、我々が観測できるのは G に基づく分布 $P(X_1, \dots, X_n)$ のみである。つまり、介入効果を知りたいときは、介入後分布 $P(X_1, \dots, X_n \mid do(X_i = x_i))$ を観察によって得られる分布 $P(X_1, \dots, X_n)$ やその周辺分布で書き下す必要がある。もし $P(X_1, \dots, X_n)$ から $P(X_1, \dots, X_n \mid do(X_i = x_i))$ を書き下すことができるとき、 $P(X_1, \dots, X_n \mid do(X_i = x_i))$ は**識別可能**であるという。次のバックドア基準は、識別可能であることの十分条件を与える。

命題 5.9：バックドア基準

確率変数 $X_1, \dots, X_n$ 、頂点集合 $V = \{X_1, \dots, X_n\}$ 、DAG $G = (V, E)$ で G は構造的因果モデルとする。 $Y, X \in V$ について、 X と Y の道であり、 X への矢線がある道を**バックドアパス**という。 V の部分集合 Z が次の 1, 2 を満足するとき、 Z は**バックドア基準**を満たすという。

1. すべてのバックドアパスをブロックする
2. Z は X の子孫を含まない

このとき、

$$P(Y \mid do(X = x)) = \sum_z P(Y \mid X = x, Z = z)P(Z = z)$$

が成り立つ。この式を**バックドア調整公式**という。

Proof. 拡張ネットワーク $G' = (V', E')$, $V' = V \cup \{F_X\}$, $E' = E \cup \{(F_X, X)\}$ を考える。さて、 F_X から Y へのパスは X を通るパスのみである。 X, Y のバックドアパスを含む場合、 Z によって、そうでない場合は X

で条件をつけることで、 F_X と Y を有向分離できるため、定理 4.6 より、

$$F_X \perp Y \mid X, Z$$

が成り立つ。ため、

$$P(Y \mid F_X = x, X = x, Z) = P(Y \mid F_X = \text{idle}, X = x, Z)$$

となり、

$$P(Y \mid \text{do}(X = x), Z) = P(Y \mid X = x, Z)$$

また、 Z は X の子孫でないため、 F_X の子孫ではない。 F_X の親は空集合であるから局所マルコフ性により、

$$Z \perp F_X$$

となるため、

$$P(Z \mid \text{do}(X = x)) = P(Z \mid F_X = x) = P(Z)$$

以上により、

$$\begin{aligned} P(Y \mid \text{do}(X = x)) &= P(Y \mid F_X = x) \\ &= \sum_z P(Y \mid F_X = x, Z = z) P(Z = z \mid F_X = x) \\ &= \sum_z P(Y \mid X = x, Z = z) P(Z = z) \end{aligned}$$

□

例 5.10 : IPW 推定

バックドア基準は $Y \mid \text{do}(X = x)$ という介入の分布を、 $P(Y \mid X = x, Z)$, $P(Z)$ という観察データを用いた分布で書き下すことを可能にする。ここで、 Z はバックドア基準を満たすとして $Y \mid \text{do}(X = x)$ の平均を求めてみよう。

$$\begin{aligned} E[Y \mid \text{do}(X = x)] &= \sum_y y P(Y = y \mid \text{do}(X = x)) \\ &= \sum_y y \sum_z P(Y = y \mid X = x, Z = z) P(Z = z) \\ &= \sum_y \sum_z y \frac{P(Y = y, X = x, Z = z)}{P(X = x, Z = z)} P(Z = z) \\ &= \sum_z \sum_y y \frac{P(Y = y, X = x, Z = z)}{P(X = x \mid Z = z)} \\ &= \sum_{x'} \sum_z \sum_y y \frac{I(x' = x) P(Y = y, X = x, Z = z)}{P(X = x' \mid Z = z)} \\ &= E \left[\frac{Y I(X = x)}{P(X = x \mid Z)} \right] \end{aligned}$$

分母の $P(X = x \mid Z)$ は傾向スコアと呼ばれ、 $e(Z)$ で表す。今、同分布から独立に抽出された標本 $(x_1, y_1, z_1), \dots, (x_n, y_n, z_n)$ について、推定量

$$\frac{1}{n} \sum_{i=1}^n \frac{y_i I(x_i = x)}{e(z_i)}$$

は $E[Y \mid \text{do}(X = x)]$ の一致かつ不偏な推定値を与える。これは Rubin 流でよく知られた **IPW 推定法** である。

例 5.11：回帰係数の解釈性

$E[Y \mid do(X = x)]$ の期待値を今一度書き直してみよう.

$$\begin{aligned}
 E[Y \mid do(X = x)] &= \sum_y y P(Y = y \mid do(X = x)) \\
 &= \sum_y y \sum_z P(Y = y \mid X = x, Z = z) P(Z = z) \\
 &= \sum_y \sum_z y P(Y = y \mid X = x, Z = z) P(Z = z) \\
 &= \sum_z \sum_y y P(Y = y \mid X = x, Z = z) P(Z = z) \\
 &= \sum_z E[Y \mid X = x, Z = z] P(Z = z)
 \end{aligned}$$

ここで, Y を X, Z を説明変数とした線形モデルを考える.

$$Y = \beta_{YX}X + \beta_{YZ}^\top Z + \varepsilon$$

条件付き期待値を計算する.

$$\begin{aligned}
 \sum_z E[Y \mid X = x, Z = z] P(Z = z) &= \sum_z (\beta_{YX}x + \beta_{YZ}^\top z) P(Z = z) \\
 &= \beta_{YX}x \cdot \sum_z P(Z = z) + \beta_{YZ}^\top \sum_z z P(Z = z) \\
 &= \beta_{YX}x + \beta_{YZ}^\top E[Z]
 \end{aligned}$$

このとき, 平均因果効果は次のように求められる.

$$E[Y \mid do(X = x_1)] - E[Y \mid do(X = x_2)] = \beta_{YX}(x_1 - x_2)$$

とくに, $x_1 - x_2 = 1$ であれば, 平均因果効果は β_{YX} そのものである. この議論において重要であるのは Z がバックドア基準を満足する集合であったことである.

1.2 で見たシミュレーションをもう一度考えてみよう. 以下に DAG と構造方程式を再掲する.

$$\begin{aligned}
 \varepsilon_X, \varepsilon_Y, \varepsilon_1, \dots, \varepsilon_6 &\stackrel{\text{i.i.d.}}{\sim} N(0, 1) \\
 X &= 0.6Z_1 + 0.6Z_5 + \varepsilon_X \\
 Y &= X + 0.6Z_2 + 0.6Z_3 + 0.6Z_6 + \varepsilon_Y \\
 Z_1 &= 0.6Z_2 + \varepsilon_1 \\
 Z_2 &= \varepsilon_2 \\
 Z_3 &= 0.5X + \varepsilon_3 \\
 Z_4 &= 0.7X + 0.7Y + \varepsilon_4 \\
 Z_5 &= \varepsilon_5 \\
 Z_6 &= \varepsilon_6
 \end{aligned}$$




図 12 データの生成過程 (再掲)

このとき、バックドア基準を満足する変数 Z_2, Z_6 を説明変数として線形回帰を行う。

表 3 バックドア変数集合によるシミュレーション結果 (n=10000)

変数	X	Z_2	Z_6
偏回帰係数	1.3004	0.5703	0.5983

この結果は 1.2 で見たシミュレーションの結果 (図 4) と一致しており、 X の回帰係数が真の平均因果効果である 1.3 に近い値を与えていることが分かる。

バックドア基準は、必要な変数がすべて観測されている場合には、介入後分布は識別可能であることを保証する。一方で必要な変数が観測されていない場合であっても、介入後分布が識別可能である場合がある。次の **do 計算法** は未観測の変数が存在する場合に、介入後分布の識別可能性を判定するための有用な計算規則である。

定理 5.12：do 計算法 (do-calculus)

G を構造的因果モデルとして、 V の互いに素な部分集合 X, Y, Z, W を考える。このとき、次の規則 1, 2, 3 が成り立つ。

規則 1 (観察の挿入・削除)

$G_{\overline{X}}$ 上で Y と Z を X, W が有向分離するならば、

$$P(Y \mid do(X = x), Z, W) = P(Y \mid do(X = x), W)$$

規則 2 (介入と観察の交換)

$G_{\overline{XZ}}$ 上で Y と Z を X, W が有向分離するならば、

$$P(Y \mid do(X = x), do(Z = z), W) = P(Y \mid do(X = x), Z, W)$$

規則 3 (介入の挿入・削除)

$G_{\overline{X}, \overline{Z(W)}}$ 上で Y と Z を X, W が有向分離するならば、

$$P(Y \mid do(X = x), do(Z = z), W) = P(Y \mid do(X = x), W)$$

ただし、 $Z(W)$ は Z に含まれる頂点のうち W に含まれる頂点の非子孫からなる集合である。

Proof. [規則 1] F_X の定義により,

$$\begin{aligned} P(Y \mid do(X = x), Z, W) &= P(Y \mid F_X = x, Z, W) \\ &= P(Y \mid F_X = x, X = x, Z, W) \end{aligned}$$

$(Y \perp Z \mid X, W)_{G_{\bar{X}}}$ より, $Y \perp Z \mid X, W, F_X = x$ が成り立つ. ゆえに,

$$\begin{aligned} P(Y \mid Z, F_X = x, X = x, W) &= P(Y \mid F_X = x, X = x, W) \\ &= P(Y \mid F_X = x, W) \\ &= P(Y \mid do(X = x), W) \end{aligned}$$

が成り立つ.

[規則 2] $(Y \perp Z \mid X, W)_{G_{\bar{X}\bar{Z}}}$ から,

$$(Y \perp F_Z \mid Z, W, X)_{G_{\bar{X}}}$$

が成り立つことを確認する. $G_{\bar{X}}$ 上で Y と F_Z が $\{Z, W, X\}$ により有向分離されていることを確認する. F_Z と Y の任意の道 p は頂点 Z を含む.

- Z が p 上の合流点であるとき, p は Z から Y へのバックドアパスを含むが $(Y \perp Z \mid X, W)_{G_{\bar{X}\bar{Z}}}$ より, $G_{\bar{X}}$ 上で, Z から Y へのバックドアパスは, X, W によりブロックされている.
- Z が p 上の非合流点であるとき, p は Z により, ブロックされている.

ゆえに,

$$(Y \perp F_Z \mid Z, W, X)_{G_{\bar{X}}}$$

したがって,

$$\begin{aligned} P(Y \mid do(X = x), do(Z = z), W) &= P(Y \mid F_X = x, F_Z = z, W) \\ &= P(Y \mid F_X = x, X = x, F_Z = z, Z = z, W) \\ &= P(Y \mid F_X = x, X = x, Z = z, W) \\ &= P(Y \mid do(X = x), Z = z, W) \end{aligned}$$

[規則 3] $(Y \perp Z \mid X, W)_{G_{\bar{X}, \bar{Z}(W)}}$ が成り立つことを確認する. $G_{\bar{X}}$ において, $\{X, W\}$ が Y と F_Z を有向分離することを確認する.

(i) Y と F_Z のパス p が Z から矢線が出るパスを含むとき: このパスは, $G_{\bar{X}, \bar{Z}(W)}$ に含まれる. ここで $(Y \perp Z \mid X, W)_{G_{\bar{X}, \bar{Z}(W)}}$ より, p は $G_{\bar{X}}$ で $\{X, W\}$ によって有向分離されることが分かる.

(ii) Y と F_Z のパス p が Z に矢線が入るパスを含むとき: X は $G_{\bar{X}}$ で Z の子孫になり得ない.

- (a) W が $G_{\bar{X}}$ で Z の子孫である場合:
パス p は $G_{\bar{X}, \bar{Z}(W)}$ に存在するパスであるが, $(Y \perp Z \mid X, W)_{G_{\bar{X}, \bar{Z}(W)}}$ より, p は $\{X, W\}$ によってブロックされている.
- (b) W が $G_{\bar{X}}$ で Z の非子孫である場合:
 Z は p の合流点であるため, p は $\{X, W\}$ によってブロックされている.

以上により,

$$(Y \perp F_Z \mid X, W)_{G_{\bar{X}}}$$

が成り立つ. したがって,

$$\begin{aligned} P(Y \mid do(X = x), do(Z = z), W) &= P(Y \mid F_X = x, W, F_Z = z) \\ &= P(Y \mid F_X = x, X = x, W, F_Z = z) \\ &= P(Y \mid F_X = x, W, F_Z = \text{idle}) \\ &= P(Y \mid do(X = x), W) \end{aligned}$$

□

do 計算法により次のフロントドア基準が導かれる。

命題 5.13：フロントドア基準

$X, Y \in V$ について、 $Z \subset V$ が次の (i), (ii), (iii) を満足するとき、 Z はフロントドア基準を満足するという。

1. Z は X から Y への有向道をブロックする。
2. X と任意の Z の元の X へのバックドアパスはすべて空集合でブロックされる。
3. Z と Y のパスで Z へのバックドアパスはすべて X でブロックされる。

このとき、次のフロントドア調整公式が成り立つ。

$$P(Y \mid do(X = x)) = \sum_z P(Z = z \mid X = x) \sum_{x'} P(Y \mid X = x', Z = z) P(X = x')$$

Proof.

$$\begin{aligned} P(Y \mid do(X = x)) &= \sum_z P(Y, Z = z \mid do(X = x)) \\ &= \sum_z P(Y \mid Z = z, do(X = x)) P(Z = z \mid do(X = x)) \end{aligned}$$

さて、(ii) から、グラフは $(X \perp Z)_{G_{\underline{X}}}$ であるため、規則 2 より、

$$\begin{aligned} P(Z \mid do(X = x)) &= P(Z \mid X = x) \\ P(Z = z \mid do(X = x)) &= P(Z = z \mid X = x) \end{aligned}$$

(iii) から、 $(Z \perp Y \mid X)_{G_{\underline{Z}}}$ であり、当然 $(Z \perp Y \mid X)_{G_{\overline{XZ}}}$ であるから、規則 2 より、

$$P(Y \mid Z = z, do(X = x)) = P(Y \mid do(Z = z), do(X = x))$$

(i) から、 $(X \perp Y \mid Z)_{G_{\overline{XZ}}}$ が成り立ったため、規則 3 より、

$$P(Y \mid do(Z = z), do(X = x)) = P(Y \mid do(Z = z))$$

ここで、(iii) から、 Y と Z のパスのうち、 Z へのバックドアパスを X がすべてブロックしているため、バックドア調整公式を用いて次のように書ける。

$$P(Y \mid do(Z = z)) = \sum_{x'} P(Y \mid X = x', Z = z) P(X = x')$$

以上により、

$$\begin{aligned} P(Y \mid do(X = x)) &= \sum_z P(Y \mid Z = z, do(X = x)) P(Z = z \mid do(X = x)) \\ &= \sum_z P(Y \mid do(Z = z)) \cdot P(Z = z \mid X = x) \\ &= \sum_z P(Z = z \mid X = x) \sum_{x'} P(Y \mid X = x', Z = z) P(X = x') \end{aligned}$$

が成り立つ。 □

例 5.14：喫煙と肺がん

喫煙と肺がんの因果関係は、かつて医学界および統計学界で大きな論争を引き起こした。当時の観測データからは、喫煙と肺がんの間に強い正の相関があることが知られていた。しかし、R.A. Fisher は、タバコを好む性質と肺がんの罹りやすさの双方を支配する「未観測の共通遺伝子」という交絡因子が存在する可能性を指摘し、喫煙そのものの因果効果を否定しようとした。

この未観測の交絡因子の問題について、フロントドア基準を用いることで、因果関係を識別できると考えられている。喫煙の有無 X 、肺がんの患者であること Y 、未観測の遺伝子 U 、さらに、肺へのタールの蓄積 C が次のような関係にあると考えられる。




図 13 喫煙と肺がんの因果関係

これは、次の 2 つを仮定している。

- X (喫煙) から Y (肺がん) への影響は、 C (タールの蓄積) を通してのみ起こる。
- U (遺伝子) と C (タールの蓄積) は U は生まれつき決まるため、 $C \rightarrow U$ の因果はなく、一方でタールが肺に蓄積する遺伝子も考えづらく、 $U \rightarrow C$ の因果もない。

この C は X, Y についてのフロントドア基準を満たす。

1. $X \rightarrow C \rightarrow Y$: X から Y への有向道であり、 $\{C\}$ でブロックされる。
2. $X \leftarrow U \rightarrow Y \leftarrow C$: バックドアパスであるが、 Y が合流点となっておりブロックされている。
3. $C \leftarrow X \leftarrow U \rightarrow Y$: バックドアパスであるが、 $\{X\}$ により、このパスはブロックされる。

ゆえにフロントドア調整公式を用いて介入後分布は識別可能である。

フロントドア基準を満たすような Z を見つければ、介入後分布は未観測の原因の存在に関わらず、識別可能である。では、一般に識別不能である DAG は存在するだろうか。

例 5.15：操作変数

観測されている X, Y, Z と未観測の U が次の DAG に従うとする。




図 14 操作変数法

このとき、 $P(Y \mid do(X = x))$ は識別不能であることが知られている。しかし、変数間に線形性を仮定すると、平均因果効果が導出できることが知られている。

実際、 $\varepsilon_Z, \varepsilon_X, \varepsilon_Y, \varepsilon_U$ は独立で平均 0、分散 1 とする。 X, Y, Z, U は次の構造方程式で生成される

$$\begin{aligned}
 Z &= \varepsilon_Z \\
 U &= \varepsilon_U \\
 X &= \beta_{XZ}Z + \beta_{XU}U + \varepsilon_X \\
 Y &= \beta_{YX}X + \beta_{YU}U + \varepsilon_Y
 \end{aligned}$$

今知りたいのは、 X から Y への直接効果 β_{YX} である。もちろん、今、 U は未観測であるから、利用できる値は相関

$$E[XY], E[XZ], E[YZ]$$

のみである。ここで相関は総合効果と交絡効果に分解できたことを思い出そう。これを用いれば、

$$\begin{aligned}E[XZ] &= \beta_{XZ} \\ E[YZ] &= \beta_{XZ}\beta_{YX}\end{aligned}$$

とできるため、

$$\beta_{YX} = \frac{\beta_{XZ}\beta_{YX}}{\beta_{XZ}} = \frac{E[YZ]}{E[XZ]}$$

と求められる。この方法を操作変数法といい、この Z を X と Y の操作変数という。

識別可能性については、次の定理が知られている。

定理 5.16：完全性定理

構造的因果モデル G と、頂点 $X, Y \in V$ を考える。介入後分布 $P(Y \mid do(X = x))$ が識別可能であることの必要十分条件は、 do 計算法を有限回用いることで介入後分布を観察可能な分布で書き下せることである。

Proof. 参考文献 [6] を参照せよ。なお、参考文献 [6] では、任意のグラフの識別可能性を判定するアルゴリズム (ID アルゴリズム) も提案されている。□

6 反事実

本章ではポテンシャルアウトカムを用いて因果推論を考察する。これは起こりえなかったこと、反事実を扱う枠組みであり、Pearl 流と Rubin 流との統合以上の意味を持つ。

定義 6.1：ポテンシャルアウトカム

$G = (V, E)$, $V = \{X_1, \dots, X_n\}$ を DAG として、各 X_i は外生変数 $\varepsilon_1, \dots, \varepsilon_n$ を用いて、

$$X_i = f_i(pa(X_i), \varepsilon_i)$$

で生成されるとする。今 $X, Y \in V$ について、新しいグラフ $G_{\bar{X}}$ と、新しいメカニズム

$$X = x$$

を考える。このとき、 $G_{\bar{X}}$ 上の Y をポテンシャルアウトカムといい、 $U = (\varepsilon_1, \dots, \varepsilon_n)$ として、

$$Y_x(U)$$

で表す。

さて、これは、介入後分布 $P(X_1, \dots, X_n \mid do(X = x))$ における Y である。ゆえに、当然

$$E[Y_x(U)] = E[Y \mid do(X = x)]$$

が成り立つ。ポテンシャルアウトカムは、 $X = x$ であったならば Y がとったであろう値という反事実的な量である。これは、必ずしも実際に観察される量ではない。しかし、次の場合は、ポテンシャルアウトカムが実際に観察される。

命題 6.2：一貫性

構造的因果モデル $G = (V, E)$ と、 $X, Y \in V$ について、ポテンシャルアウトカム $Y_x(U)$ を考える。ただし、 $U = (\varepsilon_1, \dots, \varepsilon_n)$ である。このとき、任意の $U = u$ となる u について、

$$X(u) = x \Rightarrow Y(u) = Y_x(u)$$

が成り立つ。

Proof. 頂点 $X_1, \dots, X_n$ は U の関数であるから、 $U = u$ となる u について、

$$X_i(u) = f_i(u)$$

とくに、

$$X(u) = f_X(u) = x$$

である。一方、介入後の $X_1, \dots, X_n$ においては、

$$\begin{aligned} X_i(u) &= f_i(u) \quad (X_i \neq X) \\ X(u) &= x \end{aligned}$$

であり、すべての $X_i(u)$ で、介入の前後で同一の値をとる。したがって、

$$Y(u) = Y_x(u)$$

が成り立つ。 □

一貫性は、 u を固定した場合に、 $X = x$ が観察された Y は Y_x に等しいという、当然の帰結を与える。とくに、 X が $\{0, 1\}$ の二値をとる場合、より分かりやすい (Rubin 流でもおなじみの) 表現が得られる。

係 6.3：スイッチング方程式

構造的因果モデル $G = (V, E)$ と、 $U = (\varepsilon_1, \dots, \varepsilon_n)$ として、 $X, Y \in V$ についてポテンシャルアウトカム $Y_x(U)$ を考える。とくに、 $X = \{0, 1\}$ の二値のみをとる場合、次が成り立つ。

$$Y(U) = X(U)Y_1(U) + (1 - X(U))Y_0(U)$$

Proof. $U = u$ となる u を任意にとる。

$$X(u) = 1 \text{ ならば } Y(u) = Y_1(u)$$

$$X(u) = 0 \text{ ならば } Y(u) = Y_0(u)$$

であるから、

$$Y(u) = X(u)Y_1(u) + (1 - X(u))Y_0(u)$$

が成り立つ。今、 u は任意であったから、

$$Y(U) = X(U)Y_1(U) + (1 - X(U))Y_0(U)$$

が成り立つ。 □

これは、因果推論の根本問題そのものである。 X は写像であるから、 0 と 1 を同時にとることはなく、また、 $Y_1(u)$ と $Y_0(u)$ を同時に観察されない。そして、我々が観察できるポテンシャルアウトカムは、 $X(u) = x$ が観察されたときの $Y_x(u)$ であって、 $Y_x(u)$ そのものではない。

X と Y_x が独立である (RCT) とき、

$$P(Y_x(u) \mid X(u) = x) = P(Y_x(u))$$

となるため、容易に $P(Y_x(u))$ のデータを観察できる。しかし、現実的に RCT の仮定は厳しくて、一般的に少し緩い仮定を置く。それが次の強く無視できる割当て条件 (SITA) である。

定義 6.4：強く無視できる割当て

確率変数 X とポテンシャルアウトカム Y_x が確率変数の集合 Z を与えたときに条件付き独立、つまり、

$$X \perp Y_x \mid Z$$

が成り立つとき、 X は**強く無視できる割当て条件**を満足するという。

さて、1.3 節で見たように、強く無視できる割当て条件は Rubin 流の中心的な仮定であるが、どの変数を用いれば条件付き独立性が担保されるか、明らかではない。そこでツインネットワークという道具を導入して、条件付き独立性をグラフィカルに判定しよう。

定義 6.5：ツインネットワーク

$G = (V, E)$, $V = \{X_1, \dots, X_n\}$ を DAG 各 X_i について、外生変数 $\varepsilon_1, \dots, \varepsilon_n$ を用いて、

$$X_i = f_i(pa(X_i), \varepsilon_i)$$

で生成されるとする。 $U = \{\varepsilon_1, \dots, \varepsilon_n\}$ とする。ここで、 $X_k \in V$ として、グラフ $G_{\bar{X}_k}$ で新しく、

$$X_i = f_i(pa(X_i), \varepsilon_i)$$

$$X_k = x_k$$

として生成される確率変数を $X_1^*, \dots, X_n^*$ と書く。ここで、 $nd(X_k^*)$ は、 $nd(X_k)$ の対応する添字の確率変数

と同一の確率変数である.

よって, G_{X_k} において, 頂点集合 V^* を,

$$V^* = nd(X_k) \cup de(X_k^*)$$

としても確率分布を変えない. ここで,

$$F = E \cup \{(X_i^*, X_j^*) \in E^* \mid X_i^* \in de(X_k^*) \text{ または } X_j^* \in de(X_k^*)\} \\ \cup \{(\varepsilon_i, X_i) \mid X_i \in V \text{ または } X_i \in de(X_k^*) \setminus \{X_k^*\}\}$$

とおいたときに, 有向グラフ

$$G^* = (V \cup de(X_k^*) \cup U, F)$$

をツインネットワークという.

例 6.6 :

以下に, 誤差項を加えた DAG と, 対応するツインネットワークの例を示す.




図 15 構造的因果モデル




図 16 ツインネットワーク

命題 6.7 :

ツインネットワークは, ペイジアンネットワークである.

Proof. 局所マルコフ性を証明すればよい. $X \in V \cup de(X_k^*)$ を任意にとる. 可測関数 f_X を用いて,

$$X = f_X(pa(X))$$

である. ただし $pa(X)$ は G^* 上での親である. よって任意の $W \in V \cup de(X_k^*) \cup U$ について,

$$X \perp W \mid pa(X)$$

が成り立つ. なぜなら, X は $pa(X)$ を与えたときに定数であるため, 任意の確率変数と独立である.

一方, $\varepsilon_i \in U$ を任意にとる. ε_i は外生的であるため, G 上における $nd(X_i)$ と $G_{\bar{X}_k}$ 上における $nd(X_i^*)$ の任意の元と独立である. G^* における ε_i の非子孫は, $nd(X_i) \cup nd(X_i^*)$ であって, ε_i それらと独立であるから, 任意の $V \cup de(X_k^*) \cup U$ の元について局所マルコフ性が成り立ち, ツインネットワークは, ベイジアンネットワークである. $\square$

定理 6.8 :

DAG $G = (V, E)$, $V = \{X_1, \dots, X_n\}$, $X, Y \in V$ として, Z は X に入る矢線を含むパスについてバックドア基準を満たすとする. このとき,

$$X \perp Y_x(U) \mid Z$$

が成り立つ.

Proof. Y が X の子孫でないとき: $Y_x = Y$ より, $X \perp Y \mid Z$ を示せばよい. X に入る矢線を含む X と Y のパスはすべて Z でブロックされる. 一方, X から Y への有向道が存在しない. よって, X から出る矢線を含む X と Y のパスはすべて空集合でブロックされ, Z は X の子孫を含まず, X から出る矢線を含む X と Y のパスは, 必ず, Z に含まれない合流点を持つ. よって, X と Y は Z によって有向分離されて,

$$X \perp Y_x \mid Z$$

が証明される.

Y が X の子孫であるとき: ツインネットワーク G^* を考える. ここで, $G^* = (V^*, F)$, $V^* = V \cup de(X^*) \cup U$ として,

$$S = V^* \setminus \{de(X) \cup de(X^*)\}$$

とおく. さて, S の任意の元は X または X^* の子孫ではないため, $de(X)$, $de(X^*)$ の元から S の元への矢線は存在しない. ゆえに, $de(X)$ の元と $de(X^*)$ の元のパスは, 少なくとも S の元から $de(X)$ の元, $de(X^*)$ の元に入る矢線を含まなければならない.

$$de(X) \leftarrow S \cdots S \rightarrow de(X^*)$$

さて, p を X と $Y_x = Y^*$ を結ぶパスとする.

(i) p が $de(X) \leftarrow S \rightarrow de(X)$ の経路を含むとき, $Y_x \in de(X^*)$ より,

$$de(X) \leftarrow S \rightarrow de(X) \leftarrow S$$

の経路を含む必要がある. ここで $de(X)$ は有向道のみを持つグラフであるから, 少なくとも一つの合流点を持つ.

$$S_1 \rightarrow \underbrace{X_1 \rightarrow \cdots \rightarrow X_k}_{de(X)} \leftarrow S$$

さらに, この合流点は X の子孫であるから, Z に含まれない. つまり, この道は Z でブロックされる.

(ii) p が $de(X^*) \leftarrow S \rightarrow de(X^*)$ の経路を含むとき, (i) と同様に考えれば, この道は Z でブロックされる.

(iii) p が $X \rightarrow de(X) \leftarrow S \rightarrow de(X^*) \rightarrow Y_x$ であるとき, p は X の子孫に合流点を持つ.

$$X \rightarrow \underbrace{X_1 \rightarrow \cdots \rightarrow X_k}_{de(X)} \leftarrow S$$

よって, この道は Z でブロックされる.

(iv) p が $X \leftarrow S \rightarrow de(X^*) \rightarrow Y_x$ であるとき, この経路に含まれる $de(X^*)$ の要素を $X_1^*, \dots, X_k^*$ とおく. さて, G^* の定義により, グラフ G には, X と Y の経路,

$$X \leftarrow S \rightarrow \underbrace{X_1 \rightarrow \cdots \rightarrow X_k}_{de(X)} \rightarrow Y$$

が存在する. これは X に入る矢印を含む, X と Y のバックドアパスであるために, Z によってブロックされる. ここで, $X_1, \dots, X_k, Y$ は X の子孫であるため, Z に含まれない. したがって, 経路

$$X \leftarrow S \rightarrow \underbrace{X_1^* \rightarrow \cdots \rightarrow X_k^*}_{de(X^*)} \rightarrow Y$$

も同じ集合 Z によってブロックされる.

以上により, いずれのパスも Z によってブロックされており, X と Y_x は Z によって有向分離されているため, 定理 4.6 より,

$$X \perp Y_x \mid Z$$

が成り立つ. □

因果の梯子

因果の梯子は物事の因果関係を理解する能力を 3 つの段階に分けて分類した, 思考のフレームワークである. Judea Pearl が提唱し, 解きたい問いがどの段階の能力を必要とするか分類することができる.

第 1 段: 関連付け

- 何ができるか: 見ること, 観察すること
- 発する問い: X を見たら何がわかるか. X を見たときに, Y に対する信念はどう変わるか.
- 数学的表現: $P(Y \mid X)$

第 2 段: 介入

- 何ができるか: 行動すること, 介入すること
- 発する問い: X をすればどうなるか. X に介入すれば, Y はどう変わるか.
- 数学的表現: $P(Y \mid do(X = x))$

第 3 段: 反事実

- 何ができるか: 想像すること, 過去を振り返ること.
- 発する問い: もしこうしていれば, どうなったか. X が起きなかったらどうなったか.
- 数学的表現: $P(Y_x = y \mid X = x', Y = y')$

次の反事実についての確率は因果の梯子の第 3 段を記述する確率である.

定義 6.9: 必要性・十分性・必要十分性

X, Y をともに二値 $\{0, 1\}$ をとる確率変数, Y_x をポテンシャルアウトカムとする.

(i) PN

$$PN = P(Y_0 = 0 \mid Y = 1, X = 1)$$

この PN を必要性の確率という.

(ii) PS

$$PS = P(Y_1 = 1 \mid Y = 0, X = 0)$$

この PS を十分性の確率という.

(iii) PNS

$$PNS = P(Y_1 = 1, Y_0 = 0)$$

この PNS を必要十分性の確率という.

命題 6.10 :

$$PNS = P(Y = 1, X = 1) \cdot PN + P(Y = 0, X = 0) \cdot PS$$

が成り立つ.

Proof. 一致性により,

$$\begin{aligned} P(Y = 1, X = 1) \cdot PN &= P(Y_0 = 0, Y = 1 \mid X = 1)P(X = 1) \\ &= P(Y_0 = 0, Y_1 = 1, X = 1) \end{aligned}$$

$$\begin{aligned} P(Y = 0, X = 0) \cdot PS &= P(Y_1 = 1, Y = 0 \mid X = 0)P(X = 0) \\ &= P(Y_1 = 1, Y_0 = 0, X = 0) \end{aligned}$$

したがって,

$$\begin{aligned} PNS &= P(Y_0 = 0, Y_1 = 1) \\ &= P(Y_0 = 0, Y_1 = 1, X = 1) + P(Y_0 = 0, Y_1 = 1, X = 0) \\ &= P(Y = 1, X = 1) \cdot PN + P(Y = 0, X = 0) \cdot PS \end{aligned}$$

を得る. □

命題 6.11 : Pearl-Tian Bound

X, Y をともに二値 $\{0, 1\}$ をとる確率変数, Y_x をポテンシャルアウトカムとする. 必要性の確率 PN について次の不等式が成り立つ.

$$\max \left\{ 0, \frac{P(Y = 1) - P(Y_0 = 1)}{P(X = 1, Y = 1)} \right\} \leq PN \leq \min \left\{ 1, \frac{P(Y_0 = 0) - P(X = 0, Y = 0)}{P(X = 1, Y = 1)} \right\}$$

Proof.

$$\begin{aligned} P(Y_0 = 0) &= P(Y_0 = 0, Y = 1, X = 1) + P(Y_0 = 0, Y = 1, X = 0) \\ &\quad + P(Y_0 = 0, Y = 0, X = 1) + P(Y_0 = 0, Y = 0, X = 0) \\ &= P(Y_0 = 0 \mid Y = 1, X = 1)P(Y = 1, X = 1) \\ &\quad + P(Y_0 = 0 \mid Y = 1, X = 0)P(Y = 1, X = 0) \\ &\quad + P(Y_0 = 0 \mid Y = 0, X = 1)P(Y = 0, X = 1) \\ &\quad + P(Y_0 = 0 \mid Y = 0, X = 0)P(Y = 0, X = 0) \end{aligned}$$

ここで命題 6.2 より,

$$\begin{aligned} P(Y_0 = 0 \mid Y = 1, X = 0) &= 0 \\ P(Y_0 = 0 \mid Y = 0, X = 0) &= 1 \end{aligned}$$

であるため,

$$\begin{aligned} P(Y_0 = 0) &= P(Y_0 = 0 \mid Y = 1, X = 1)P(Y = 1, X = 1) \\ &\quad + P(Y_0 = 0, Y = 0, X = 1) + P(Y = 0, X = 0) \end{aligned}$$

となる。ゆえに,

$$PN = \frac{P(Y_0 = 0) - P(Y_0 = 0 \mid Y = 0, X = 1)P(Y = 0, X = 1) - P(Y = 0, X = 0)}{P(Y = 1, X = 1)}$$

が導かれる。ここで

$$0 \leq P(Y_0 = 0 \mid Y = 0, X = 1) \leq 1$$

より, $P(Y_0 = 0 \mid Y = 0, X = 1) = 1, P(Y_0 = 0 \mid Y = 0, X = 1) = 0$ をそれぞれ代入することで, 以下の不等式を得る.

$$\begin{aligned} PN &\geq \frac{P(Y_0 = 0) - P(Y = 0, X = 1) - P(Y = 0, X = 0)}{P(Y = 1, X = 1)} \\ &= \frac{P(Y_0 = 0) - P(Y = 0)}{P(Y = 1, X = 1)} \\ &= \frac{(1 - P(Y_0 = 1)) - (1 - P(Y = 1))}{P(Y = 1, X = 1)} \\ &= \frac{P(Y = 1) - P(Y_0 = 1)}{P(Y = 1, X = 1)} \\ PN &\leq \frac{P(Y_0 = 0) - P(Y = 0, X = 0)}{P(Y = 1, X = 1)} \end{aligned}$$

さらに $0 \leq PN \leq 1$ も考慮すれば求める不等式を得る. □

より一般的に, 反事実の確率は, 線形計画問題に帰着できる. $i, j, k \in \{0, 1\}$ として,

$$p_{ijk} = P(Y_0 = i, Y_1 = j, X = k)$$

とおく. ここで, 介入と観察を何らかの方法で推定できたとしよう. このとき, 一致性により,

$$P(Y_0 = i, Y_1 = j, X = k) = P(Y_0 = i, Y_1 = j, X = k, Y = Y_k)$$

であることに注意すると, p_{ijk} についての制約は次で書ける.

- 観察についての制約

$$\begin{aligned} P(X = 0, Y = 0) &= P(Y_0 = i, Y_1 = j, X = 0, Y = Y_0 = 0) \\ &= P(Y_0 = 0, Y_1 = j, X = 0) \\ &= p_{010} + p_{000} \end{aligned}$$

$$\begin{aligned} P(X = 0, Y = 1) &= p_{100} + p_{110} \\ P(X = 1, Y = 0) &= p_{001} + p_{101} \end{aligned}$$

- 介入についての制約

$$\begin{aligned} P(Y_0 = 0) &= p_{000} + p_{001} + p_{010} + p_{011} \\ P(Y_1 = 0) &= p_{010} + p_{011} + p_{110} + p_{111} \end{aligned}$$

- 確率としての制約

$$\sum_{i,j,k=0}^1 p_{ijk} = 1, \quad p_{ijk} \geq 0$$

この 6 本の線形等式制約と、すべての確率が 0 より大きいという不等式制約を実行可能領域 $\mathcal{F}$ とする。この定式化により、反事実の確率はそれぞれ、

$$\begin{aligned} PN &= \frac{P(Y_0 = 0, X = 1, Y = 1)}{P(X = 1, Y = 1)} \\ &= \frac{P(Y_0 = 0, Y_1 = 1, X = 1)}{P(X = 1, Y = 1)} = \frac{p_{011}}{P(X = 1, Y = 1)} \\ PS &= \frac{P(Y_1 = 1, X = 0, Y = 0)}{P(X = 0, Y = 0)} = \frac{p_{010}}{P(X = 0, Y = 0)} \\ PNS &= p_{010} + p_{011} \end{aligned}$$

と表せるため、それぞれ実行可能領域 $\mathcal{F}$ 上の制約付き最大値・最小値を計算すれば、PN, PS, PNS についての不等式を得る。これは、与えられた条件の中で最も狭い範囲の不等式である。実は、命題 6.11 の Pearl-Tian Bound は PN の最もシャープな不等式である。

定理 6.12 : Balk & Pearl (1994)

X, Y をともに二値 $\{0, 1\}$ をとる確率変数、 Y_x をポテンシャルアウトカムとする。PN, PS, PNS の最も狭い範囲の不等式は、次で与えられる。

$$\begin{aligned} \max \left\{ \begin{array}{c} 0 \\ P(Y_1 = 1) - P(Y_0 = 1) \\ P(Y = 1) - P(Y_0 = 1) \\ P(Y_1 = 1) - P(Y = 1) \end{array} \right\} &\leq PNS \leq \min \left\{ \begin{array}{c} P(Y_1 = 1) \\ P(Y_0 = 0) \\ P(X = 0, Y = 0) + P(X = 1, Y = 1) \\ P(Y_1 = 1) - P(Y_0 = 1) + P(X = 1, Y = 0) + P(X = 0, Y = 1) \end{array} \right\} \\ \max \left\{ \begin{array}{c} 0 \\ \frac{P(Y=1)-P(Y_0=1)}{P(X=1,Y=1)} \end{array} \right\} &\leq PN \leq \min \left\{ \begin{array}{c} 1 \\ \frac{P(Y_0=0)-P(Y=0,X=0)}{P(Y=0,X=0)} \end{array} \right\} \\ \max \left\{ \begin{array}{c} 0 \\ \frac{P(Y_1=1)-P(Y=1)}{P(Y=0,X=0)} \end{array} \right\} &\leq PS \leq \min \left\{ \begin{array}{c} 1 \\ \frac{P(Y_1=1)-P(Y=1,X=1)}{P(X=0,Y=0)} \end{array} \right\} \end{aligned}$$

Proof. 参考文献 [7] を参照せよ。 □

反事実の確率は、一般的に一点に識別することは出来ず、範囲で与えられる。しかし、次の仮定の下で識別可能であることが知られている。

定理 6.13 : 単調性

X, Y をともに二値 $\{0, 1\}$ をとる確率変数、 $Y_x(U)$ をポテンシャルアウトカムとする。ポテンシャルアウトカム $Y_1(U), Y_0(U)$ と任意の $U = u$ について、

$$Y_1(u) \geq Y_0(u)$$

が成り立つとき、

$$PNS = P(Y_1 = 1) - P(Y_0 = 1)$$

参考文献

- [1] J. Pearl 著, 黒木学訳, 『統計的因果推論 ―モデル・推論・推測―』, 共立出版, 2009.
- [2] 宮川雅巳著, 『統計的因果推論 ―回帰分析の新しい枠組み―』, 朝倉書店, 2004.
- [3] 宮川雅巳著, 『グラフィカルモデル』, 朝倉書店, 1997.
- [4] J. Pearl, D. Mackenzie 著, 夏目大訳, 『因果推論の科学 「なぜ？」の問いにどう答えるか』, 文藝春秋, 2022.
- [5] S. L. Lauritzen, A. P. Dawid, B. N. Larsen, and H. G. Leimer, “Independence properties of directed Markov fields,” *Networks*, Vol. 20, No. 5, pp. 491–505, 1990.
- [6] I. Shpitser and J. Pearl, “Identification of Joint Causal Effects in the Graphs with Confounded Joint Effects,” in *Proceedings of the 21st National Conference on Artificial Intelligence (AAAI-06)*, 2006, pp. 1219–1226.
- [7] J. Tian and J. Pearl, “Probabilities of Causation: Bounds and Identification,” *Proceedings of the Sixteenth Conference on Uncertainty in Artificial Intelligence*, pp. 589–598, 2000.
- [8] P. D. Stolley, “When genius errs: R.A. Fisher and the lung cancer controversy,” *American Journal of Epidemiology*, vol. 133, no. 5, pp. 416–425, 1991.